

Resolução dos Exercícios das Listas

Inferência Bayesiana | 1º/2024

Tailine J. S. Nonato

July 8, 2024

Lista 2

Questão 1

O seu professor chega na sala de aula e mostra uma moeda. Você suspeita que a moeda possa ser falsa e ter duas caras. Considere a priori probabilidades iguais para os eventos da moeda ser falsa ou ser honesta (i.e. uma moeda bem equilibrada).

(i) Calcule a sua probabilidade de obter cara num lançamento dessa moeda.

- Entende-se que:

$$C = \{cara\}$$

$$H = \{honesta\}$$

$$F = \{falsa\}$$

- Assim, a priori é dada por:

$$P(F) = P(H) = 0.5$$

- A probabilidade de obter cara num lançamento é dada por:

$$P(C) = P(C|F)P(F) + P(C|H)P(H)$$

$$P(C) = 1 \cdot 0.5 + 0.5 \cdot 0.5$$

$$P(C) = 0.75$$

(ii) Se o professor lançar a moeda e o resultado for cara, qual é agora a probabilidade dela ser falsa?

- A probabilidade de ser falsa dado que o resultado foi cara é dada por:

$$P(F|C) = \frac{P(C|F)P(F)}{P(C)}$$

$$P(F|C) = \frac{1 \cdot 0.5}{0.75}$$

$$P(F|C) = \frac{0.5}{0.75}$$

$$P(F|C) = \frac{2}{3}$$

(iii) Se o professor lançar a moeda n vezes e obter n caras, qual é a probabilidade dela ser falsa? Estude o comportamento desta probabilidade para n grande.

- A probabilidade de ser falsa dado que o resultado foi cara n vezes é dada por:

$$P(F|nC) = \frac{P(nC|F)P(F)}{P(nC)}$$

$$P(F|nC) = \frac{P(C|F)^n P(F)}{P(C)^n}$$

$$P(F|nC) = \frac{1^n \cdot 0.5}{0.75^n}$$

$$P(F|nC) = \left(\frac{2}{3}\right)^n$$

(iv) Se o professor lançar a moeda uma vez e obter cara, qual é a probabilidade do próximo lançamento ser cara?

- A probabilidade do próximo lançamento ser cara dado que o resultado foi cara é dada por:

$$P(C|C) = \frac{P(C|F)P(F)}{P(C)}$$

$$P(C|C) = \frac{1 \cdot 0.5}{0.75}$$

$$P(C|C) = \frac{0.5}{0.75}$$

$$P(C|C) = \frac{2}{3}$$

(v) Explique porque é falso neste contexto a afirmação “os dois lançamentos da moeda são independentes”, e explique qual seria a afirmação correta.

- A probabilidade do segundo lançamento ser cara depende do resultado do primeiro lançamento. A afirmação correta seria “os dois lançamentos da moeda são condicionalmente independentes”, ou seja, a probabilidade do segundo lançamento ser cara dado que o primeiro foi cara é igual à probabilidade do segundo lançamento ser cara dado que o primeiro foi coroa.

Questão 2

Seja y_1, y_2, \dots, y_n uma amostra da distribuição de Bernoulli com probabilidade de sucesso θ e considere uma distribuição a priori uniforme para θ .

(i) Ache a distribuição a posteriori de θ e a sua média e variância.

Entende-se que:

$$s = \sum_{i=1}^n y_i \sim \text{Binomial}(n, \theta)$$

$$P(\theta) \sim \text{Uniforme}(0, 1)$$

Assim, a priori é dada por:

$$P(\theta) = \frac{1}{b-a} = \frac{1}{1-0} = 1, \quad 0 < \theta < 1$$

A posteriori pode ser obtida por:

$$\theta|x \propto P(x|\theta)P(\theta)$$

$$\theta|x \propto \theta^s (1-\theta)^{n-s} * 1$$

Manipulando a expressão, tem-se:

$$\theta|x \propto \theta^{s+1-1} (1-\theta)^{n-s+1-1}$$

Assim, a posteriori é dada por:

$$\theta|x \sim \text{Beta}(s+1, n-s+1)$$

Logo, pela distribuição, a média e a variância da posteriori são dadas por:

$$E(\theta|x) = \frac{s+1}{s+1+n-s+1} = \frac{s+1}{n+2}$$

$$\text{Var}(\theta|x) = \frac{(s+1)(n-s+1)}{(s+1+n-s+1)^2(s+1+n-s+1+1)} = \frac{(s+1)(n-s+1)}{(n+2)^2(n+3)}$$

(ii) Mostre que é possível expressar a esperança a posteriori de θ da forma $(1-w)E(\theta) + w\hat{\theta}$, onde $E(\theta)$ e $\hat{\theta}$ são respectivamente a esperança a priori e a estimativa máximo verossímil de θ , e interprete este resultado.

A esperança a priori de θ é dada por:

$$E(\theta) = \frac{1}{2}$$

A estimativa máximo verossímil de θ é dada por:

$$\hat{\theta} = \frac{s}{n}$$

Assim, a esperança a posteriori de θ pode ser expressa como:

$$E(\theta|x) = \frac{s+1}{n+2} = \frac{n}{n+2} \cdot \frac{s}{n} + \frac{2}{n+2} \cdot \frac{1}{2}$$

$$E(\theta|x) = \frac{n}{n+2} \hat{\theta} + \frac{2}{n+2} E(\theta)$$

Sendo $w = \frac{n}{n+2}$, tem-se:

$$E(\theta|x) = (1-w)E(\theta) + w\hat{\theta}$$

(iii) Se y_{n+1} é uma observação futura deste processo de Bernoulli, ache a distribuição preditiva $p(y_{n+1}|y_1, \dots, y_n)$.

A distribuição preditiva é dada por:

$$\begin{aligned} p(y_{n+1}|y_1, \dots, y_n) &= \int p(y_{n+1}|\theta)p(\theta|y_1, \dots, y_n)d\theta \\ p(y_{n+1}|y_1, \dots, y_n) &= \int \theta^{y_{n+1}}(1-\theta)^{1-y_{n+1}} \frac{s+1}{n+2} \theta^s (1-\theta)^{n-s} d\theta \\ p(y_{n+1}|y_1, \dots, y_n) &= \frac{s+1}{n+2} \int \theta^{s+y_{n+1}}(1-\theta)^{n-s+1-y_{n+1}} d\theta \\ p(y_{n+1}|y_1, \dots, y_n) &= \frac{s+1}{n+2} \frac{\Gamma(s+y_{n+1}+1)\Gamma(n-s+1-y_{n+1}+1)}{\Gamma(n+2)} \end{aligned}$$

Questão 4

No exercício 2, calcule

(i) a estimativa bayesiana para Perda Quadrática

- A perda quadrática é dada por:

$$L(\theta, \hat{\theta}) = (\theta - \hat{\theta})^2$$

- Assim, a estimativa bayesiana para perda quadrática é dada por:

$$\begin{aligned} E[L(\theta, \hat{\theta})|x] &= E[(\theta - \hat{\theta})^2|x] \\ E[L(\theta, \hat{\theta})|x] &= E[\theta^2 - 2\theta\hat{\theta} + \hat{\theta}^2|x] \\ E[L(\theta, \hat{\theta})|x] &= E[\theta^2|x] - 2E[\theta\hat{\theta}|x] + E[\hat{\theta}^2|x] \\ E[L(\theta, \hat{\theta})|x] &= E[\theta^2|x] - 2\hat{\theta}E[\theta|x] + \hat{\theta}^2 \\ E[L(\theta, \hat{\theta})|x] &= Var(\theta|x) + E[\theta|x]^2 - 2\hat{\theta}E[\theta|x] + \hat{\theta}^2 \\ E[L(\theta, \hat{\theta})|x] &= \frac{(s+1)(n-s+1)}{(n+2)^2(n+3)} + \left(\frac{s+1}{n+2}\right)^2 - 2\hat{\theta}\frac{s+1}{n+2} + \hat{\theta}^2 \end{aligned}$$

- Isolando $\hat{\theta}$, tem-se:

$$\hat{\theta} = \frac{n}{n+2}\hat{\theta} + \frac{2}{n+2}\frac{1}{2}$$

$$\hat{\theta} = \frac{n}{n+2}\hat{\theta} + \frac{1}{n+2}$$

$$\hat{\theta} = \frac{n}{n+2}\frac{s}{n} + \frac{1}{n+2}$$

$$\hat{\theta} = \frac{s}{n+2} + \frac{1}{n+2}$$

$$\hat{\theta} = \frac{s+1}{n+2}$$

(ii) o limite da estimativa bayesiana para Perda Zero-Um quando $\epsilon \rightarrow \theta$.

- A perda zero-um é dada por:

$$L(\theta, \hat{\theta}) = I(\theta \neq \hat{\theta})$$

- Assim, o limite da estimativa bayesiana para perda zero-um é dado por:

$$E[L(\theta, \hat{\theta})|x] = E[I(\theta \neq \hat{\theta})|x]$$

$$E[L(\theta, \hat{\theta})|x] = P(\theta \neq \hat{\theta}|x)$$

$$E[L(\theta, \hat{\theta})|x] = 1 - P(\theta = \hat{\theta}|x)$$

- Sabe-se que:

$$P(\theta = \hat{\theta}|x) = P(\theta = \frac{s+1}{n+2}|x) = 0$$

- Logo, o limite da estimativa bayesiana para perda zero-um é dado por:

$$\lim_{\epsilon \rightarrow \theta} E[L(\theta, \hat{\theta})|x] = 1$$

No caso especial que $n = 12, s = \sum_{i=1}^{12} y_i = 9$, calcule

(iii) a estimativa bayesiana sob Perda Absoluta

- A perda absoluta é dada por:

$$L(\theta, \hat{\theta}) = |\theta - \hat{\theta}|$$

- Assim, a estimativa bayesiana para perda absoluta é dada por:

$$E[L(\theta, \hat{\theta})|x] = E[|\theta - \hat{\theta}|^2|x]$$

- Sabe-se que:

$$E[L(\theta, \hat{\theta})|x] = E[(\theta - \hat{\theta})^2|x]$$

$$E[L(\theta, \hat{\theta})|x] = \frac{(s+1)(n-s+1)}{(n+2)^2(n+3)} + \left(\frac{s+1}{n+2}\right)^2 - 2\hat{\theta}\frac{s+1}{n+2} + \hat{\theta}^2$$

- Com $s = 9$ e $n = 12$, tem-se:

$$\hat{\theta} = \frac{s+1}{n+2}$$

```
s<-9
n<-12
theta<- (s+1)/(n+2)
theta
```

```
[1] 0.7142857
```

(iv) um intervalo HPD com nível 99%

- O intervalo HPD é dado por:

$$HPD = [\theta_{(1-\alpha)/2}, \theta_{(1+\alpha)/2}]$$

- Assim, o intervalo HPD com nível 99% é dado por:

$$HPD = [\theta_{0.005}, \theta_{0.995}]$$

- Com $s = 9$ e $n = 12$, tem-se:

$$\theta|x \sim Beta(9+1, 12-9+1)$$

- Logo, o intervalo HPD com nível 99% é dado por:

```
qbeta(0.005, 10, 4)
```

```
[1] 0.3793642
```

```
qbeta(0.995, 10, 4)
```

```
[1] 0.942924
```

Questão 8

Suponha que (x_1, x_2, x_3) dado p_1, p_2, p_3 segue uma distribuição Multinomial com parâmetros n e (p_1, p_2, p_3) , onde $p_i \geq 0$ e $p_1 + p_2 + p_3 = 1$, e que, a priori, (p_1, p_2, p_3) segue uma distribuição de Dirichlet com parâmetros $(\alpha_1, \alpha_2, \alpha_3)$.

(i) Ache a distribuição a posteriori de p_1, p_2, p_3 e as distribuições a posteriori marginais de p_i ($i = 1, 2, 3$)

- Entende-se que:

$$(x_1, x_2, x_3) \sim \text{Multinomial}(n, (p_1, p_2, p_3))$$

$$P(p_1, p_2, p_3) \sim \text{Dirichlet}(\alpha_1, \alpha_2, \alpha_3)$$

- Assim, a priori é dada por:

$$P(p_1, p_2, p_3) = \frac{1}{B(\alpha_1, \alpha_2, \alpha_3)} p_1^{\alpha_1-1} p_2^{\alpha_2-1} p_3^{\alpha_3-1}$$

- A posteriori pode ser obtida por:

$$p_1, p_2, p_3 | x \propto P(x | p_1, p_2, p_3) P(p_1, p_2, p_3)$$

$$p_1, p_2, p_3 | x \propto p_1^{x_1} p_2^{x_2} p_3^{x_3} p_1^{\alpha_1-1} p_2^{\alpha_2-1} p_3^{\alpha_3-1}$$

$$p_1, p_2, p_3 | x \propto p_1^{x_1+\alpha_1-1} p_2^{x_2+\alpha_2-1} p_3^{x_3+\alpha_3-1}$$

- Assim, a posteriori é dada por:

$$p_1, p_2, p_3 | x \sim \text{Dirichlet}(x_1 + \alpha_1, x_2 + \alpha_2, x_3 + \alpha_3)$$

- As distribuições a posteriori marginais de p_i são dadas por:

$$p_i | x = \int p_1, p_2, p_3 | x dp_1 dp_2 dp_3$$

$$p_i | x = \int p_1, p_2, p_3 | x \prod_{j \neq i} dp_j$$

$$p_i | x = \int p_1^{x_1+\alpha_1-1} p_2^{x_2+\alpha_2-1} p_3^{x_3+\alpha_3-1} dp_1 dp_2 dp_3$$

$$p_i | x = \int p_i^{x_i+\alpha_i-1} (1 - p_i)^{n-x_i+\alpha_{-i}-1} dp_i$$

- Logo, é possível observar que:

$$p_i | x = \frac{B(x_i + \alpha_i, n - x_i + \alpha_{-i})}{B(\alpha_i, \alpha_{-i})}$$

- Então, as distribuições a posteriori marginais de p_i são dadas por:

$$p_i|x \sim \text{Beta}(x_i + \alpha_i, n - x_i + \alpha_{-i})$$

(ii) Calcule as estimativas bayesianas de p_i e de $p_j - p_i$ sob Perda Quadrática ($i, j = 1, 2, 3, i \neq j$).

- A estimativa bayesiana de p_i sob perda quadrática é dada por:

$$E[L(p_i, \hat{p}_i)|x] = E[(p_i - \hat{p}_i)^2|x]$$

$$E[L(p_i, \hat{p}_i)|x] = E[(p_i - E(p_i|x))^2|x]$$

$$E[L(p_i, \hat{p}_i)|x] = \text{Var}(p_i|x)$$

$$E[L(p_i, \hat{p}_i)|x] = \frac{(x_i + \alpha_i)(n - x_i + \alpha_{-i})}{(n + \alpha_{-i})^2(n + \alpha)}$$

- A estimativa bayesiana de $p_j - p_i$ sob perda quadrática é dada por:

$$E[L(p_j - p_i, \hat{p}_j - \hat{p}_i)|x] = E[(p_j - p_i - \hat{p}_j + \hat{p}_i)^2|x]$$

$$E[L(p_j - p_i, \hat{p}_j - \hat{p}_i)|x] = E[(p_j - \hat{p}_j - p_i + \hat{p}_i)^2|x]$$

$$E[L(p_j - p_i, \hat{p}_j - \hat{p}_i)|x] = E[(p_j - \hat{p}_j)^2 + (p_i - \hat{p}_i)^2 - 2(p_j - \hat{p}_j)(p_i - \hat{p}_i)|x]$$

$$E[L(p_j - p_i, \hat{p}_j - \hat{p}_i)|x] = E[(p_j - \hat{p}_j)^2|x] + E[(p_i - \hat{p}_i)^2|x] - 2E[(p_j - \hat{p}_j)(p_i - \hat{p}_i)|x]$$

$$E[L(p_j - p_i, \hat{p}_j - \hat{p}_i)|x] = \text{Var}(p_j|x) + \text{Var}(p_i|x) - 2\text{Cov}(p_j, p_i|x)$$

$$E[L(p_j - p_i, \hat{p}_j - \hat{p}_i)|x] = \frac{(x_j + \alpha_j)(n - x_j + \alpha_{-j})}{(n + \alpha_{-j})^2(n + \alpha)} + \frac{(x_i + \alpha_i)(n - x_i + \alpha_{-i})}{(n + \alpha_{-i})^2(n + \alpha)} - 2\frac{\alpha_{ij}}{(n + \alpha_{-i})(n + \alpha_{-j})}$$

- Sendo $\alpha_{ij} = \alpha_i \alpha_j / (\alpha + 1)$, tem-se:

$$E[L(p_j - p_i, \hat{p}_j - \hat{p}_i)|x] = \frac{(x_j + \alpha_j)(n - x_j + \alpha_{-j})}{(n + \alpha_{-j})^2(n + \alpha)} + \frac{(x_i + \alpha_i)(n - x_i + \alpha_{-i})}{(n + \alpha_{-i})^2(n + \alpha)} - 2\frac{\alpha_i \alpha_j}{(n + \alpha_{-i})(n + \alpha_{-j})(n + \alpha)}$$

Questão 11

É conhecido que 25% dos pacientes de um certo grupo que sofrem de enxaqueca melhoram após duas horas de serem tratados com um placebo. Para verificar se uma droga nova é melhor que o placebo, $n = 20$ pacientes foram tratados com o placebo e verificou-se que após duas horas $s = 8$ deles relataram ter melhorado. Seja θ a probabilidade de um paciente tratado com a droga nova melhorar após duas horas.

(i) Especifique a hipótese nula H_0 e a alternativa H_1 ;

$$\begin{cases} H_0 : \theta \leq 0.25 \\ H_1 : \theta > 0.25 \end{cases}$$

(ii) Usando a distribuição a priori “não informativa” $\theta \sim Uniforme(0, 1)$, calcule as chances relativas a priori e a posteriori de H_1 e o correspondente Fator de Bayes;

- Entende-se que:

$$\sum X_i \sim^{iid} Binomial(20, \theta)$$

$$P(\theta) \sim Uniforme(0, 1)$$

- Assim, a priori é dada por:

$$P(\theta) = \frac{1}{b-a} = \frac{1}{1-0} = 1, \quad 0 < \theta < 1$$

- Logo, as probabilidades a priori são dadas por:

$$P(H_0) = P(\theta \leq 0.25) = \int_0^{0.25} 1d\theta = 0.25$$

$$P(H_1) = P(\theta > 0.25) = \int_{0.25}^1 1d\theta = 0.75$$

- Odds a priori

$$odds(\theta \leq 0.25) = \frac{P(\theta \leq 0.25)}{P(\theta > 0.25)} = \frac{0.25}{0.75} = \frac{1}{3}$$

$$odds(\theta > 0.25) = \frac{P(\theta > 0.25)}{P(\theta \leq 0.25)} = \frac{0.75}{0.25} = 3$$

- Pode-se concluir assim que a priori a chance de H_1 é 3 vezes maior que a chance de H_0 .

- Sabe-se que:

$$\theta|x \propto P(x|\theta)P(\theta)$$

$$\theta|x \propto \theta^s(1-\theta)^{n-s} * 1$$

- Manipulando a expressão, tem-se:

$$\theta|x \propto \theta^{s+1-1}(1-\theta)^{n-s+1-1}$$

- Assim, a posteriori é dada por:

$$\theta|x \sim Beta(s+1, n-s+1)$$

- Com $s = 8$ e $n = 20$, tem-se:

$$\theta|x \sim Beta(9, 13)$$

- Logo, as probabilidades a posteriori são dadas por:

$$P(H_0|x) = P(\theta \leq 0.25|s = 8)$$

```
ph0<-round(pbeta(0.25, 9, 13),3)
ph0
```

```
[1] 0.056
```

$$P(H_1|x) = P(\theta > 0.25|s = 8)$$

```
ph1<-round(1 - pbeta(0.25, 9, 13),3)
ph1
```

```
[1] 0.944
```

- Odds a posteriori

$$odds(\theta \leq 0.25) = 0.056 / 0.944 = 0.059$$

$$odds(\theta > 0.25) = 0.944 / 0.056 = 16.857$$

- Pode-se concluir assim que a posteriori a chance de H_1 é 16.86 vezes maior que a chance de H_0 .
- Fator de Bayes

$$\beta_{1,0} = \frac{odds(\theta_1|x)}{odds(\theta_1)} = 16.8/3 = 5.6 \text{ em favor de } H_1.$$

$$\beta_{0,1} = \frac{odds(\theta_0|x)}{odds(\theta_0)} = 3/16.8 = 0.18 \text{ em favor de } H_0.$$

- Assim, a interpretação do Fator de Bayes é que a evidência a favor de H_1 é 5.6 vezes mais forte que a evidência a favor de H_0 .

(iii) Seja $d = 1$ a decisão de rejeitar H_0 e $d = 0$ a de não rejeitar. Considere a função de perda de Neyman para a qual é 5 vezes mais custoso rejeitar H_0 quando ela é verdadeira do que não rejeitar quando ela é falsa [isto é, $L(d = 1, \theta \in H_0) = 5L(d = 0, \theta \notin H_0)$, $L(d = 1, \theta \notin H_0) = L(d = 0, \theta \in H_0) = 0$]. Calcule a decisão ótima a posteriori;

$$d = \begin{cases} 1 & \text{se } L(d = 1|x) < L(d = 0|x) \\ 0 & \text{se } L(d = 1|x) > L(d = 0|x) \end{cases}$$

- Perda a posteriori

$$L(d = 1|x) = E[L(d = 1|x, \theta)]$$

$$L(d = 0|x) = E[L(d = 0|x, \theta)]$$

- Com $L(d = 1, \theta \in H_0) = 5L(d = 0, \theta \notin H_0)$, tem-se:

$$L(d = 1|x) = 5L(d = 0|x)$$

- Assim, a decisão ótima a posteriori é dada por:

$$\begin{cases} d = 1, & \text{se } 5P(H_0|x) < P(H_1|x) \\ d = 0, & \text{se } 5P(H_0|x) > P(H_1|x) \end{cases}$$

(iv) É razoável chamar essa distribuição a priori de “não informativa” nesse problema? Se a sua resposta for negativa, sugira uma outra distribuição a priori e refaça os cálculos anteriores.

- Não é razoável, visto que ao assumir uma distribuição a priori uniforme, supõe-se que todas as probabilidades são igualmente prováveis, gerando um viés na análise. Uma distribuição a priori mais adequada seria a distribuição Beta(0.5, 0.5), que assume que a probabilidade de sucesso é igualmente provável de ser maior ou menor que 0.5.
- Refazendo os cálculos anteriores, tem-se:
- A priori é dada por:

$$P(\theta) = \frac{\theta^{0.5-1}(1-\theta)^{0.5-1}}{B(0.5,0.5)}$$

- Logo, as probabilidades a priori são dadas por:

$$P(H_0) = P(\theta \leq 0.25) = \int_0^{0.25} \frac{\theta^{0.5-1}(1-\theta)^{0.5-1}}{B(0.5,0.5)} d\theta$$

```
ph0<-round(pbeta(0.25, 0.5, 0.5),3)
ph0
```

[1] 0.333

$$P(H_1) = P(\theta > 0.25) = \int_{0.25}^1 \frac{\theta^{0.5-1}(1-\theta)^{0.5-1}}{B(0.5,0.5)} d\theta$$

```
ph1<-round(1 - pbeta(0.25, 0.5, 0.5),3)
ph1
```

[1] 0.667

- Odds a priori

$$odds(\theta \leq 0.25) = \frac{P(\theta \leq 0.25)}{P(\theta > 0.25)} = \frac{0.25}{0.75} = \frac{1}{3}$$

$$odds(\theta > 0.25) = \frac{P(\theta > 0.25)}{P(\theta \leq 0.25)} = \frac{0.75}{0.25} = 3$$

- Pode-se concluir assim que a priori a chance de H_1 é 3 vezes maior que a chance de H_0 .
- Sabe-se que:

$$\theta|x \propto P(x|\theta)P(\theta)$$

$$\theta|x \propto \theta^s(1-\theta)^{n-s} * \frac{\theta^{0.5-1}(1-\theta)^{0.5-1}}{B(0.5,0.5)}$$

- Manipulando a expressão, tem-se:

$$\theta|x \propto \theta^{s+0.5-1}(1-\theta)^{n-s+0.5-1}$$

- Assim, a posteriori é dada por:

$$\theta|x \sim \text{Beta}(s+0.5, n-s+0.5)$$

- Com $s = 8$ e $n = 20$, tem-se:

$$\theta|x \sim \text{Beta}(8.5, 12.5)$$

- Logo, as probabilidades a posteriori são dadas por:

$$P(H_0|x) = P(\theta \leq 0.25|s = 8)$$

```
ph0<-round(pbeta(0.25, 8.5, 12.5),3)
ph0
```

```
[1] 0.066
```

$$P(H_1|x) = P(\theta > 0.25|s = 8)$$

```
ph1<-round(1 - pbeta(0.25, 8.5, 12.5),3)
ph1
```

```
[1] 0.934
```

- Odds a posteriori

$$odds(\theta \leq 0.25) = 0.066 / 0.934 = 0.071$$

$$odds(\theta > 0.25) = 0.934 / 0.066 = 14.152$$

- Fator de Bayes

$$\beta_{1,0} = \frac{\text{odds}(\theta_1|x)}{\text{odds}(\theta_1)} = 14.15/0.071 = 199.3 \text{ em favor de } H_1.$$

$$\beta_{0,1} = \frac{\text{odds}(\theta_0|x)}{\text{odds}(\theta_0)} = 0.071/14.15 = 0.005 \text{ em favor de } H_0.$$

- Conclui-se assim que a evidência a favor de H_1 é 199.3 vezes mais forte que a evidência a favor de H_0 . Logo, a escolha da distribuição a priori gera resultados diferentes, de forma que a distribuição Beta(0.5, 0.5) fornece uma evidência mais forte a favor de H_1 e é mais adequada para o problema.

Lista 3.1

Questão 1

1. Seja x_1, x_2, \dots, x_n uma amostra da distribuição de Poisson com média θ , e considere a priori que θ tem uma distribuição Gama com parâmetros α e β (ou seja, com média $\frac{\alpha}{\beta}$ e variância $\frac{\alpha}{\beta^2}$).

(i) Ache a distribuição a posteriori de θ e sua média e variância.

- Entende-se que:

$$x_i \sim \text{Poisson}(\theta)$$

$$\theta \sim \text{Gama}(\alpha, \beta)$$

- Assim, a priori é dada por:

$$P(\theta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta}$$

- A posteriori pode ser obtida por:

$$\theta|x \propto P(x|\theta)P(\theta)$$

$$\theta|x \propto \theta^{\sum x_i} e^{-n\theta} \theta^{\alpha-1} e^{-\beta\theta}$$

$$\theta|x \propto \theta^{\sum x_i + \alpha - 1} e^{-(n+\beta)\theta}$$

- Assim, a posteriori é dada por:

$$\theta|x \sim \text{Gama}(\sum x_i + \alpha, n + \beta)$$

- Logo, a média e a variância da posteriori são dadas por:

$$E(\theta|x) = \frac{\sum x_i + \alpha}{n + \beta}$$

$$Var(\theta|x) = \frac{\sum x_i + \alpha}{(n + \beta)^2}$$

(ii) Mostre que é possível expressar a esperança a posteriori de θ da forma $w\bar{x} + (1 - w)\frac{\alpha}{\beta}$, e interprete este resultado.

- A esperança a priori de θ é dada por:

$$E(\theta) = \frac{\alpha}{\beta}$$

- Assim, a esperança a posteriori de θ pode ser expressa como:

$$E(\theta|x) = \frac{\sum x_i + \alpha}{n + \beta} = \frac{n}{n + \beta} \frac{\sum x_i}{n} + \frac{\beta}{n + \beta} \frac{\alpha}{\beta}$$

$$E(\theta|x) = \frac{n}{n + \beta} \bar{x} + \frac{\beta}{n + \beta} \frac{\alpha}{\beta}$$

- Sendo $w = \frac{n}{n + \beta}$, tem-se:

$$E(\theta|x) = w\bar{x} + (1 - w)\frac{\alpha}{\beta}$$

- Assim, a interpretação deste resultado é que a esperança a posteriori de θ é uma combinação linear entre a média amostral \bar{x} e a média a priori $\frac{\alpha}{\beta}$, onde o peso w é dado pela razão entre o tamanho amostral n e a soma do tamanho amostral com o parâmetro β .

(iii) O que acontece na parte (ii) quando β é grande com $\frac{\alpha}{\beta}$ fixo? Interprete!

- Quando β é grande, o peso w tende a 1, de forma que a esperança a posteriori de θ se aproxima da média amostral \bar{x} , ou seja, a informação a priori é desconsiderada e a estimativa é baseada apenas na informação amostral. Assim, a interpretação é que a medida que o parâmetro β aumenta, a influência da informação a priori diminui e a estimativa se aproxima da média amostral.

(iv) Mostre que existe um número c tal que a variância a posteriori é maior do que a variância a priori sempre que $\bar{x} > c$, ache c e interprete este resultado.

- A variância a priori de θ é dada por:

$$Var(\theta) = \frac{\alpha}{\beta^2}$$

- Assim, a variância a posteriori de θ é dada por:

$$Var(\theta|x) = \frac{\sum x_i + \alpha}{(n + \beta)^2}$$

- Para que a variância a posteriori seja maior que a variância a priori, é necessário que:

$$\frac{\sum x_i + \alpha}{(n + \beta)^2} > \frac{\alpha}{\beta^2}$$

$$\frac{\sum x_i + \alpha}{n + \beta} > \frac{\alpha}{\beta}$$

$$\frac{\sum x_i}{n} + \frac{\alpha}{n + \beta} > \frac{\alpha}{\beta}$$

$$\frac{\sum x_i}{n} > \frac{\alpha}{\beta} - \frac{\alpha}{n + \beta}$$

$$\frac{\sum x_i}{n} > \frac{\alpha}{\beta} - \frac{\alpha}{n + \beta}$$

$$\frac{\sum x_i}{n} > \frac{\alpha(n + \beta) - \alpha\beta}{\beta(n + \beta)}$$

$$\frac{\sum x_i}{n} > \frac{\alpha n}{\beta(n + \beta)}$$

$$\frac{\sum x_i}{n} > \frac{\alpha}{\beta} \cdot \frac{n}{n + \beta}$$

- Assim, o número c é dado por:

$$c = \frac{\alpha}{\beta}$$

- A interpretação deste resultado é que a variância a posteriori de θ é maior que a variância a priori sempre que a média amostral \bar{x} for maior que a razão entre os parâmetros α e β , ou seja, a variância a posteriori é maior que a variância a priori quando a média amostral é maior que a média a priori.

Questão 3

Seja x_1, x_2, \dots, x_n uma amostra da distribuição de Poisson com média θ , e considere a priori que θ tem uma distribuição Gama com parâmetros $\alpha = 1$ e $\beta = 1$. Ache:

(a) a estimativa bayesiana de θ no caso de perda quadrática

- A perda quadrática é dada por:

$$L(\theta, \hat{\theta}) = (\theta - \hat{\theta})^2$$

- Assim, a estimativa bayesiana de θ sob perda quadrática é dada por:

$$E[L(\theta, \hat{\theta})|x] = E[(\theta - \hat{\theta})^2|x]$$

$$E[L(\theta, \hat{\theta})|x] = E[\theta^2 - 2\theta\hat{\theta} + \hat{\theta}^2|x]$$

$$E[L(\theta, \hat{\theta})|x] = E[\theta^2|x] - 2E[\theta\hat{\theta}|x] + E[\hat{\theta}^2|x]$$

$$E[L(\theta, \hat{\theta})|x] = \text{Var}(\theta|x) + E[\theta|x]^2 - 2\hat{\theta}E[\theta|x] + \hat{\theta}^2$$

$$E[L(\theta, \hat{\theta})|x] = \frac{1}{1} + \left(\frac{1}{2}\right)^2 - 2\hat{\theta} \cdot \frac{1}{2} + \hat{\theta}^2$$

$$E[L(\theta, \hat{\theta})|x] = 1 + \frac{1}{4} - \hat{\theta} + \hat{\theta}^2$$

$$E[L(\theta, \hat{\theta})|x] = \frac{5}{4} - \hat{\theta} + \hat{\theta}^2$$

- Assim, a estimativa bayesiana de θ sob perda quadrática é dada por:

$$\hat{\theta} = \frac{1}{2}$$

(b) o limite do estimativa bayesiana sob perda zero-um quando $\epsilon \rightarrow 0$.

- A perda zero-um é dada por:

$$L(\theta, \hat{\theta}) = I(\theta \neq \hat{\theta})$$

- Assim, o limite da estimativa bayesiana sob perda zero-um é dado por:

$$E[L(\theta, \hat{\theta})|x] = E[I(\theta \neq \hat{\theta})|x]$$

$$E[L(\theta, \hat{\theta})|x] = P(\theta \neq \hat{\theta}|x)$$

$$E[L(\theta, \hat{\theta})|x] = 1 - P(\theta = \hat{\theta}|x)$$

- Sendo $\hat{\theta} = \frac{1}{2}$, tem-se:

$$P(\theta = \hat{\theta}|x) = P(\theta = \frac{1}{2}|x)$$

$$P(\theta = \hat{\theta}|x) = \frac{1}{1} \cdot \frac{1}{2} e^{-\frac{1}{2}}$$

$$P(\theta = \hat{\theta}|x) = \frac{1}{2} e^{-\frac{1}{2}}$$

- Assim, o limite da estimativa bayesiana sob perda zero-um quando $\epsilon \rightarrow 0$ é dado por:

$$E[L(\theta, \hat{\theta})|x] = 1 - \frac{1}{2} e^{-\frac{1}{2}}$$

Para o caso $n = 10$ e $\bar{x} = 1.55$, ache:

(c) a estimativa bayesiana sob perda absoluta

- A perda absoluta é dada por:

$$L(\theta, \hat{\theta}) = |\theta - \hat{\theta}|$$

- Assim, a estimativa bayesiana de θ sob perda absoluta é dada por:

$$E[L(\theta, \hat{\theta})|x] = E[|\theta - \hat{\theta}|^2|x]$$

- Com $\hat{\theta} = \frac{1}{2}$, $n = 10$ e $\bar{x} = 1.55$, tem-se:

$$E[L(\theta, \hat{\theta})|x] = E[|\theta - \frac{1}{2}|^2|x]$$

$$E[L(\theta, \hat{\theta})|x] = E[\theta^2 - \theta + \frac{1}{4}|x]$$

$$E[L(\theta, \hat{\theta})|x] = E[\theta^2|x] - E[\theta|x] + \frac{1}{4}$$

$$E[L(\theta, \hat{\theta})|x] = Var(\theta|x) + E[\theta|x]^2 - E[\theta|x] + \frac{1}{4}$$

$$E[L(\theta, \hat{\theta})|x] = \frac{1}{1} + \left(\frac{1}{2}\right)^2 - \frac{1}{2} + \frac{1}{4}$$

$$E[L(\theta, \hat{\theta})|x] = 1 + \frac{1}{4} - \frac{1}{2} + \frac{1}{4}$$

$$E[L(\theta, \hat{\theta})|x] = \frac{5}{4} - \frac{1}{2} + \frac{1}{4}$$

$$E[L(\theta, \hat{\theta})|x] = \frac{3}{4}$$

(d) o intervalo HPD para θ com nível 95%

- Como $\theta \sim Gama(1, 1)$, com $n = 10$, tem-se:

O intervalo HPD para θ com nível 95% é dado por:

```
qgamma(0.025, 1, 1)
```

```
[1] 0.02531781
```

```
qgamma(0.975, 1, 1)
```

```
[1] 3.688879
```

Questão 5

Seja x_1, x_2, \dots, x_n uma amostra da distribuição Normal com média μ e variância ϕ^{-1} conhecida, e considere a distribuição a priori $\mu \sim N(\mu_0, \tau^{-1})$.

(i) Ache a distribuição a posteriori de μ .

- Entende-se que:

$$x_i \sim Normal(\mu, \phi^{-1})$$

$$\mu \sim Normal(\mu_0, \tau^{-1})$$

- Assim, a priori é dada por:

$$P(\mu) = \frac{1}{\sqrt{2\pi\tau}} e^{-\frac{1}{2\tau}(\mu-\mu_0)^2}$$

- A posteriori pode ser obtida por:

$$\mu|x \propto P(x|\mu)P(\mu)$$

$$\mu|x \propto \prod_{i=1}^n \frac{1}{\sqrt{2\pi\phi^{-1}}} e^{-\frac{1}{2\phi^{-1}}(x_i-\mu)^2} \cdot \frac{1}{\sqrt{2\pi\tau}} e^{-\frac{1}{2\tau}(\mu-\mu_0)^2}$$

$$\mu|x \propto e^{-\frac{1}{2\phi^{-1}} \sum_{i=1}^n (x_i-\mu)^2} \cdot e^{-\frac{1}{2\tau}(\mu-\mu_0)^2}$$

$$\mu|x \propto e^{-\frac{1}{2\phi^{-1}} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2)} \cdot e^{-\frac{1}{2\tau}(\mu^2 - 2\mu\mu_0 + \mu_0^2)}$$

$$\mu|x \propto e^{-\frac{1}{2\phi^{-1}} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2) - \frac{1}{2\tau}(\mu^2 - 2\mu\mu_0 + \mu_0^2)}$$

- Logo,

$$\mu|x \sim Normal\left(\frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}, \frac{1}{n/\phi + 1/\tau}\right)$$

(ii) Mostre que é possível expressar a esperança a posteriori de μ da forma $w\bar{x} + (1-w)\mu_0$, e interprete este resultado.

- A esperança a priori de μ é dada por:

$$E(\mu) = \mu_0$$

- Assim, a esperança a posteriori de μ pode ser expressa como:

$$E(\mu|x) = \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}$$

$$E(\mu|x) = \frac{n\mu_0 + \sum x_i}{n + \phi/\tau}$$

$$E(\mu|x) = \frac{n}{n + \phi/\tau} \bar{x} + \frac{\phi/\tau}{n + \phi/\tau} \mu_0$$

- Sendo $w = \frac{n}{n + \phi/\tau}$, tem-se:

$$E(\mu|x) = w\bar{x} + (1-w)\mu_0$$

(iii) Se \bar{x}_m é a média de m observações futuras x_{n+1}, \dots, x_{n+m} , condicionalmente independentes de x_1, \dots, x_n , ache a distribuição preditiva $p(\bar{x}_m|x_1, \dots, x_n)$.

- Entende-se que:

$$\bar{x}_m = \frac{\sum_{i=n+1}^{n+m} x_i}{m}$$

- Assim, a distribuição preditiva é dada por:

$$p(\bar{x}_m|x) = \int p(\bar{x}_m|\mu)p(\mu|x)d\mu$$

$$p(\bar{x}_m|x) = \int Normal(\bar{x}_m|\mu, \phi^{-1}/m)Normal(\mu|\frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}, \frac{1}{n/\phi + 1/\tau})d\mu$$

$$p(\bar{x}_m|x) = \int \frac{1}{\sqrt{2\pi\phi^{-1}/m}}e^{-\frac{1}{2\phi^{-1}/m}(\bar{x}_m-\mu)^2} \cdot \frac{1}{\sqrt{2\pi\frac{1}{n/\phi + 1/\tau}}}e^{-\frac{1}{2\frac{1}{n/\phi + 1/\tau}}(\mu - \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau})^2}d\mu$$

$$p(\bar{x}_m|x) = \int \frac{1}{\sqrt{2\pi\phi^{-1}/m}}e^{-\frac{1}{2\phi^{-1}/m}(\bar{x}_m-\mu)^2} \cdot \frac{1}{\sqrt{2\pi\frac{1}{n/\phi + 1/\tau}}}e^{-\frac{1}{2\frac{1}{n/\phi + 1/\tau}}(\mu - \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau})^2}d\mu$$

- Assim,

$$p(\bar{x}_m|x) \sim Normal(\bar{x}_m|\frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}, \frac{1}{n/\phi + 1/\tau} + \phi^{-1}/m)$$

(iv) Discuta o que acontece com os resultados anteriores quando a distribuição a priori $p(\mu) \propto 1$ (ou seja, o caso limite quando $\tau \rightarrow 0$).

- Quando a distribuição a priori é uniforme, a informação a priori é desconsiderada e a estimativa é baseada apenas na informação amostral. Assim, a média a posteriori de μ é dada pela média amostral \bar{x} , a variância a posteriori de μ é dada pela variância amostral ϕ^{-1}/n e a distribuição preditiva é dada por:

$$p(\bar{x}_m|x) \sim Normal(\bar{x}_m|\bar{x}, \phi^{-1}/n + \phi^{-1}/m)$$

- Assim, a interpretação é que a medida que o parâmetro τ tende a zero, a influência da informação a priori diminui e a estimativa se aproxima da média amostral, a variância a posteriori de μ diminui e a distribuição preditiva é dada pela média amostral e pela variância amostral.

Questão 6

Seja x_1, x_2, \dots, x_n uma amostra da distribuição Normal com média μ e variância ϕ^{-1} conhecida, e considere a distribuição a priori $\mu \sim N(\mu_0, \tau^{-1})$.

(a): Ache o estimador bayesiano de μ no caso de

(i) perda quadrática ($L(\hat{\mu}, \mu) = (\hat{\mu} - \mu)^2$),

- Para encontrar $\hat{\mu}$ sob perda quadrática, é necessário minimizar a perda esperada:

$$E[L(\hat{\mu}, \mu)|x] = E[(\hat{\mu} - \mu)^2|x]$$

$$E[L(\hat{\mu}, \mu)|x] = E[\hat{\mu}^2 - 2\hat{\mu}\mu + \mu^2|x]$$

$$E[L(\hat{\mu}, \mu)|x] = E[\hat{\mu}^2|x] - 2E[\hat{\mu}\mu|x] + E[\mu^2|x]$$

$$E[L(\hat{\mu}, \mu)|x] = Var(\hat{\mu}|x) + E[\hat{\mu}|x]^2 - 2\mu E[\hat{\mu}|x] + \mu^2$$

$$E[L(\hat{\mu}, \mu)|x] = \frac{1}{n/\phi+1/\tau} + E[\hat{\mu}|x]^2 - 2\mu E[\hat{\mu}|x] + \mu^2$$

- Assim, a estimativa bayesiana de μ sob perda quadrática é dada por:

$$\hat{\mu} = E[\mu|x] = \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}$$

(ii) perda absoluta ($L(\hat{\mu}, \mu) = |\hat{\mu} - \mu|$)

- Para encontrar $\hat{\mu}$ sob perda absoluta, o processo é similar:

$$E[L(\hat{\mu}, \mu)|x] = E[|\hat{\mu} - \mu|x]$$

- Logo,

$$\hat{\mu} = E[\mu|x] = \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}$$

(iii) perda zero-um ($L(\hat{\mu}, \mu) = I(|\hat{\mu} - \mu| \geq \epsilon)$).

- Para encontrar $\hat{\mu}$ sob perda zero-um, o processo também é similar:

$$E[L(\hat{\mu}, \mu)|x] = E[I(|\hat{\mu} - \mu| \geq \epsilon)|x]$$

- Assim,

$$\hat{\mu} = E[\mu|x] = \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}$$

(b): Ache o intervalo HPD para μ com nível $100(1 - \alpha)\%$

- O intervalo HPD para μ com nível $100(1 - \alpha)\%$ é dado por:

```
qnorm(0.025, 1.5, 1/sqrt(10))
```

```
[1] 0.880205
```

```
qnorm(0.975, 1.5, 1/sqrt(10))
```

```
[1] 2.119795
```

Lista 3.2

Questão 1

Considere o modelo $X \sim \text{Uniforme}(\theta, \theta + 1)$ ($-\infty < \theta < \infty$).

(a) Mostre que θ é um parâmetro de localização.

- Para mostrar que θ é um parâmetro de localização, é necessário verificar se a distribuição é invariante por translação, ou seja, se $X - \theta$ tem a mesma distribuição que X .

$$P(X - \theta) = \int_{\theta}^{\theta+1} \frac{1}{1} dx = 1$$

- Logo, a distribuição de $X - \theta$ é constante, de forma que $X - \theta$ tem a mesma distribuição que X e θ é um parâmetro de localização.

(b) Dada a priori não informativa usual para o modelo de localização, $p(\theta) \propto 1$ e uma amostra aleatória X_1, \dots, X_n do modelo acima, discuta a propriedade da distribuição a posteriori.

- A priori não informativa usual para o modelo de localização é dada por:

$$p(\theta) \propto 1$$

- Assim, a distribuição a posteriori de θ é dada por:

$$\theta|x \propto P(x|\theta)P(\theta)$$

$$\theta|x \propto \prod_{i=1}^n \frac{1}{1} \cdot 1$$

$$\theta|x \propto 1$$

- Assim, a distribuição a posteriori de θ é constante, de forma que a informação a priori não influencia a estimativa de θ .

(c) Na situação da parte (b), ache:

(i) os estimadores bayesianos sob Perda Quadrática e sob Perda Absoluta;

- O estimador bayesiano de θ sob perda quadrática é dado por:

$$\hat{\theta} = E[\theta|x] = \int \theta p(\theta|x) d\theta$$

- O estimador bayesiano de θ sob perda absoluta é dado por:

$$\hat{\theta} = \text{mediana}(\theta|x)$$

(ii) O intervalo HPD para θ com credibilidade $100(1 - \alpha)\%$

- O intervalo HPD para θ com credibilidade $100(1 - \alpha)\%$ é dado por:

`qunif(alpha/2, min(x), max(x))`

`qunif(1-alpha/2, min(x), max(x))`

(iii) A probabilidade a posteriori do evento $\theta > \theta_0$.

- A probabilidade a posteriori do evento $\theta > \theta_0$ é dada por:

$$P(\theta > \theta_0 | x) = \int_{\theta_0}^{\infty} p(\theta | x) d\theta$$

$$P(\theta > \theta_0 | x) = \int_{\theta_0}^{\infty} 1 d\theta$$

$$P(\theta > \theta_0 | x) = 1 - \theta_0$$

Questão 2

Considere o modelo $X \sim \text{Uniforme}(0, \theta)$ ($0 < \theta < \infty$).

(a) Mostre que $\sigma = \theta^{-1}$ é um parâmetro de escala.

- Para mostrar que $\sigma = \theta^{-1}$ é um parâmetro de escala, é necessário verificar se a distribuição é invariante por escala, ou seja, se X/θ tem a mesma distribuição que X .

$$P(X/\theta) = \int_0^{\theta} \frac{1}{\theta} dx = 1$$

- Logo, a distribuição de X/θ é constante, de forma que X/θ tem a mesma distribuição que X e $\sigma = \theta^{-1}$ é um parâmetro de escala.

(b) Dada a priori não informativa usual para o modelo de escala, $p(\sigma) \propto \sigma^{-1}$ e uma amostra aleatória X_1, \dots, X_n do modelo acima, discuta a propriedade da distribuição a posteriori.

- A priori não informativa usual para o modelo de escala é dada por:

$$p(\sigma) \propto \sigma^{-1}$$

- Assim, a distribuição a posteriori de σ é dada por:

$$\sigma | x \propto P(x | \sigma) P(\sigma)$$

$$\sigma | x \propto \prod_{i=1}^n \frac{1}{\sigma} \cdot \sigma^{-1}$$

$$\sigma | x \propto \frac{1}{\sigma^n}$$

(c) Na situação da parte (b), ache:

(i) os estimadores bayesianos sob Perda Quadrática e sob Perda Absoluta;

- O estimador bayesiano de σ sob perda quadrática é dado por:

$$\hat{\sigma} = E[\sigma|x] = \int \sigma p(\sigma|x) d\sigma$$

- O estimador bayesiano de σ sob perda absoluta é dado por:

$$\hat{\sigma} = \text{mediana}(\sigma|x)$$

(ii) O intervalo HPD para θ com credibilidade $100(1 - \alpha)\%$

- O intervalo HPD para θ com credibilidade $100(1 - \alpha)\%$ é dado por:

$$\text{qunif}(\alpha/2, \min(\mathbf{x}), \max(\mathbf{x}))$$

$$\text{qunif}(1-\alpha/2, \min(\mathbf{x}), \max(\mathbf{x}))$$

(iii) A probabilidade a posteriori do evento $\theta > \theta_0$.

- A probabilidade a posteriori do evento $\theta > \theta_0$ é dada por:

$$P(\theta > \theta_0|x) = \int_{\theta_0}^{\infty} p(\theta|x) d\theta$$

$$P(\theta > \theta_0|x) = \int_{\theta_0}^{\infty} \frac{1}{\theta^n} d\theta$$

$$P(\theta > \theta_0|x) = -\frac{1}{(n-1)\theta^{n-1}} \Big|_{\theta_0}^{\infty}$$

$$P(\theta > \theta_0|x) = \frac{1}{(n-1)\theta_0^{n-1}}$$

Questão 3

Considere o modelo $x_1, \dots, x_n | \theta \sim \text{Ber}(\theta)$.

(a) Calcule a priori de Jeffreys e mostre que ela é própria.

- A priori de Jeffreys é dada por:

$$p(\theta) \propto \sqrt{I(\theta)}$$

$$I(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \log f(x|\theta) \right]$$

$$I(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \log \theta^x (1 - \theta)^{1-x} \right]$$

$$I(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} (x \log \theta + (1 - x) \log(1 - \theta)) \right]$$

$$I(\theta) = -E \left[\frac{\partial}{\partial \theta} \left(\frac{x}{\theta} - \frac{1-x}{1-\theta} \right) \right]$$

$$I(\theta) = -E \left[\frac{-x}{\theta^2} + \frac{1-x}{(1-\theta)^2} \right]$$

$$I(\theta) = E \left[\frac{x}{\theta^2} + \frac{1-x}{(1-\theta)^2} \right]$$

$$I(\theta) = \frac{1}{\theta^2} E[x] + \frac{1}{(1-\theta)^2} E[1-x]$$

$$I(\theta) = \frac{1}{\theta^2} \theta + \frac{1}{(1-\theta)^2} (1-\theta)$$

$$I(\theta) = \frac{1}{\theta} + \frac{1}{1-\theta}$$

- Assim, a priori de Jeffreys é dada por:

$$p(\theta) \propto \sqrt{\frac{1}{\theta} + \frac{1}{1-\theta}}$$

- Para mostrar que a priori de Jeffreys é própria, é necessário verificar se a integral da priori é finita:

$$\int \sqrt{\frac{1}{\theta} + \frac{1}{1-\theta}} d\theta$$

```
integrate(function(theta) sqrt(1/theta + 1/(1-theta)), lower = 0, upper = 1)$value
```

[1] 3.141593

- Assim, como a integral é finita, a priori de Jeffreys é própria.

(b) Considere uma amostra aleatória X_1, \dots, X_n do modelo acima e a priori de Jeffreys. Ache o estimador bayesiano de θ sob Perda Quadrática e explique como achar um intervalo HPD para θ com credibilidade $100(1 - \alpha)\%$.

- O estimador bayesiano de θ sob perda quadrática é dado por:

$$\hat{\theta} = E[\theta|x] = \int \theta p(\theta|x) d\theta$$

- Um exemplo de cálculo do intervalo HPD para θ com credibilidade $100(1 - \alpha)\%$ pode ser dado por:

```
qbeta(alpha/2, sum(x), n - sum(x))
```

```
qbeta(1-alpha/2, sum(x), n - sum(x))
```


Lista 4

Questão 1

Considere uma amostra y_1, \dots, y_n da distribuição Normal com média μ e variância $\sigma^2 = 1/\tau$ desconhecidas, e suponha que a priori a distribuição de (μ, τ) é especificada da seguinte forma: $\mu|\tau \sim N(\mu_0, 1/\lambda_0\tau)$ e $\tau \sim \text{Gama}(\alpha_0, \beta_0)$, onde λ_0 , α_0 e β_0 são positivas.

(a) Ache a distribuição a posteriori de $p(\mu, \tau|D)$ e as distribuições marginais $p(\mu|D)$ e $p(\tau|D)$.

- A distribuição a posteriori de $p(\mu, \tau|D)$ é dada por:

$$p(\mu, \tau|D) \propto p(D|\mu, \tau)p(\mu|\tau)p(\tau)$$

$$p(\mu, \tau|D) \propto \prod_{i=1}^n \frac{1}{\sqrt{2\pi\tau}} e^{-\frac{1}{2\tau}(y_i - \mu)^2} \cdot \frac{1}{\sqrt{2\pi\lambda_0\tau}} e^{-\frac{1}{2\lambda_0\tau}(\mu - \mu_0)^2} \cdot \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \tau^{\alpha_0-1} e^{-\beta_0\tau}$$

$$p(\mu, \tau|D) \propto \frac{1}{\sqrt{2\pi\tau}^n} e^{-\frac{1}{2\tau}\sum_{i=1}^n (y_i - \mu)^2} \cdot \frac{1}{\sqrt{2\pi\lambda_0\tau}} e^{-\frac{1}{2\lambda_0\tau}(\mu - \mu_0)^2} \cdot \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \tau^{\alpha_0-1} e^{-\beta_0\tau}$$

$$p(\mu, \tau|D) \propto \tau^{n/2-1} e^{-\frac{1}{2\tau}\sum_{i=1}^n (y_i - \mu)^2} \cdot \tau^{1/2} e^{-\frac{1}{2\lambda_0\tau}(\mu - \mu_0)^2} \cdot \tau^{\alpha_0-1} e^{-\beta_0\tau}$$

$$p(\mu, \tau|D) \propto \tau^{n/2+1/2+\alpha_0-1} e^{-\frac{1}{2\tau}\sum_{i=1}^n (y_i - \mu)^2 - \frac{1}{2\lambda_0\tau}(\mu - \mu_0)^2 - \beta_0\tau}$$

$$p(\mu, \tau|D) \propto \tau^{n/2+1/2+\alpha_0-1} e^{-\frac{1}{2\tau}(\sum_{i=1}^n (y_i - \mu)^2 + \frac{1}{\lambda_0}(\mu - \mu_0)^2 + 2\beta_0)}$$

- Assim, a distribuição a posteriori de $p(\mu, \tau|D)$ é dada por:

$$p(\mu, \tau|D) \sim \text{Gama}(\alpha_0 + n/2, \frac{1}{2}(\sum_{i=1}^n y_i^2 + \frac{1}{\lambda_0}(\mu - \mu_0)^2 + 2\beta_0))$$

(b) Discuta neste contexto o uso da distribuição a priori não informativa $p(\mu, \tau) \propto 1/\tau$. A distribuição a posteriori é própria? Qual é a relação da distribuição $p(\mu|D)$ e os resultados clássicos?

- A priori não informativa $p(\mu, \tau) \propto 1/\tau$ é uma distribuição imprópria, de forma que a distribuição a posteriori é própria. A distribuição a posteriori de μ é dada por:

$$p(\mu|D) = \int p(\mu, \tau|D) d\tau$$

- A distribuição a posteriori de μ é dada por:

$$p(\mu|D) \sim t_{2\alpha_0+n}(\mu_0, \frac{1}{\lambda_0(\alpha_0+n)})$$

Questão 2c

Seja $\mathbf{n} = (n_1, \dots, n_k)$ um vetor aleatório com distribuição multinomial e densidade $p(\mathbf{n}|\theta) \propto \prod_{i=1}^k \theta_i^{n_i}$, onde $\theta = (\theta_1, \dots, \theta_k)$, $\theta_i > 0$ e $\sum_i \theta_i = 1$. Considere a priori para θ uma distribuição de Dirichlet com parâmetro $\alpha = (\alpha_1, \dots, \alpha_k)$, isto é $p(\theta) \propto \prod_{i=1}^k \theta_i^{\alpha_i-1}$.

(c) No caso particular $\alpha = (0, 0, \dots, 0)$ a distribuição a priori de θ é imprópria. Mostre que a distribuição a posteriori é própria se e somente se $n_i > 0$ para $i = 1, 2, \dots, k$.

Questão 3

Na véspera do primeiro turno para a eleição de governador do DF em 2010, a Datafolha divulgou uma pesquisa indicando que, de 891 eleitores entrevistados que já tinham decidido em quem votar, Agnelo Queiroz tinha a preferência de 467, Weslian Roriz de 315 e outros candidatos de 109 eleitores. Formule um modelo para analisar esses dados. O interesse centra fundamentalmente em três perguntas:

(a) a eleição poderia ser definida no primeiro turno?

- A eleição poderia ser definida no primeiro turno se o candidato Agnelo tivesse mais de 50% dos votos válidos. Assim, o modelo pode ser formulado como:

$$p(\theta) \propto \theta^{467} (1 - \theta)^{315}$$

(b) O candidato Agnelo poderia ser eleito no primeiro turno?

- Assim, a probabilidade de Agnelo ser eleito no primeiro turno é dada por:

$$P(\theta > 0.5) = 1 - \Phi\left(\frac{\log\left[\frac{0.5}{1-0.5}\right] - 0.75}{\sqrt{1+782}}\right)$$

$$P(\theta > 0.5) = 1 - \Phi\left(\frac{\log\left[\frac{1}{2}\right] - 0.75}{\sqrt{783}}\right)$$

$$P(\theta > 0.5) = 1 - \Phi\left(\frac{-0.6931 - 0.75}{\sqrt{783}}\right)$$

$$P(\theta > 0.5) = 1 - \Phi\left(\frac{-1.4431}{\sqrt{783}}\right)$$

$$P(\theta > 0.5) = 1 - \Phi(-0.0516)$$

$$P(\theta > 0.5) = 1 - 0.4794$$

$$P(\theta > 0.5) = 0.5206$$

(c) qual será a diferença na porcentagem dos votos válidos entre os dois primeiros colocados?

- A diferença na porcentagem dos votos válidos entre os dois primeiros colocados é dada por:

$$P(\theta_1 - \theta_2 > 0) = 1 - \Phi\left(\frac{\log\left[\frac{467}{782}1 - \frac{467}{782}\right] - 0.75}{\sqrt{1+782}}\right)$$

- Calculando, o resultado é:

$$P(\theta_1 - \theta_2 > 0) = 1 - \Phi\left(\frac{\log\left[\frac{467}{782}1 - \frac{467}{782}\right] - 0.75}{\sqrt{1+782}}\right)$$

Lista 5

Questão 2

Considere $n = 12$ ensaios de Bernoulli com probabilidade de sucesso p e $y = 9$ sucessos. Suponha que a distribuição a priori de p é especificada de forma que $\eta = \log\left[\frac{p}{1-p}\right]$ segue uma distribuição Normal com média $\mu = 0$ e variância $\sigma^2 = 1$. Obtenha aproximações para $\mathbb{E}(p|y = 9)$, $\text{DP}(p|y = 9)$ e $\Pr(p > \frac{1}{2}|y = 9)$. Repita o exercício para os casos que $\sigma^2 = 4$ e 9 e compare com o caso $\sigma^2 = 1$.

- A distribuição a priori de η é dada por:

$$p(\eta) = \frac{1}{\sqrt{2\pi}} e^{-\frac{\eta^2}{2}}$$

- Assim, a distribuição a posteriori de η é dada por:

$$p(\eta|y) \propto p(y|\eta)p(\eta)$$

$$p(\eta|y) \propto \binom{12}{9} e^{9\eta} (1 - e^\eta)^3 e^{-\frac{\eta^2}{2}}$$

- A distribuição a posteriori de η é dada por:

$$p(\eta|y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(\eta - 0.75)^2}{2(1+12)}}$$

- Assim, a distribuição a posteriori de p é dada por:

$$p(p|y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(\log\left[\frac{p}{1-p}\right] - 0.75)^2}{2(1+12)}}$$

- A esperança a posteriori de p é dada por:

$$\mathbb{E}(p|y) = \frac{1}{1+e^{-0.75}}$$

- A variância a posteriori de p é dada por:

$$\text{Var}(p|y) = \frac{1}{(1+e^{-0.75})^2} \cdot \frac{e^{-0.75}}{(1+e^{-0.75})^2}$$

- A probabilidade a posteriori de $p > \frac{1}{2}$ é dada por:

$$\Pr(p > \frac{1}{2}|y) = 1 - \Phi\left(\frac{\log[\frac{1}{2}1-\frac{1}{2}]-0.75}{\sqrt{1+12}}\right)$$

- Assim, para $\sigma^2 = 4$:

$$p(p|y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(\log[\frac{p}{1-p}]-0.75)^2}{2(4+12)}}$$

$$\mathbb{E}(p|y) = \frac{1}{1+e^{-0.75}}$$

$$\text{Var}(p|y) = \frac{1}{(1+e^{-0.75})^2} \cdot \frac{e^{-0.75}}{(4+12)^2}$$

$$\Pr(p > \frac{1}{2}|y) = 1 - \Phi\left(\frac{\log[\frac{1}{2}1-\frac{1}{2}]-0.75}{\sqrt{4+12}}\right)$$

- E, para $\sigma^2 = 9$:

$$p(p|y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(\log[\frac{p}{1-p}]-0.75)^2}{2(9+12)}}$$

$$\mathbb{E}(p|y) = \frac{1}{1+e^{-0.75}}$$

$$\text{Var}(p|y) = \frac{1}{(1+e^{-0.75})^2} \cdot \frac{e^{-0.75}}{(9+12)^2}$$

$$\Pr(p > \frac{1}{2}|y) = 1 - \Phi\left(\frac{\log[\frac{1}{2}1-\frac{1}{2}]-0.75}{\sqrt{9+12}}\right)$$