

# Correções: Resolução das Listas

Inferência Bayesiana | 1º/2024

Tailine J. S. Nonato

September 26, 2024

## Sumário

Itens com alterações estão em **azul**.

Abaixo também é possível encontrar um resumo de alterações:

### 1. Lista 2

- Questão 1 (iii)
- Questão 2 (ii) e (iii)
- Questão 4 (ii), (iii) e (iv)
- Questão 8 (ii)
- Questão 11 (iii) e (iv)

### 2. Lista 3.1

- Questão 1 (iii)
- Questão 3 (a), (b), (c) e (d)
- Questão 6 (b)

### 3. Lista 3.2

- Questão 1 (a), (b), (c)
- Questão 2 (a), (b), (c)

### 4. Lista 4

- Questão 2 (c)

- Questão 3 (a)

## Lista 2

### Questão 1

O seu professor chega na sala de aula e mostra uma moeda. Você suspeita que a moeda possa ser falsa e ter duas caras. Considere a priori probabilidades iguais para os eventos da moeda ser falsa ou ser honesta (i.e. uma moeda bem equilibrada).

(i) Calcule a sua probabilidade de obter cara num lançamento dessa moeda.

- Entende-se que:

$$C = \{cara\}$$

$$H = \{honesta\}$$

$$F = \{falsa\}$$

- Assim, a priori é dada por:

$$P(F) = P(H) = 0.5$$

- A probabilidade de obter cara num lançamento é dada por:

$$P(C) = P(C|F)P(F) + P(C|H)P(H)$$

$$P(C) = 1 \cdot 0.5 + 0.5 \cdot 0.5$$

$$P(C) = 0.75$$

(ii) Se o professor lançar a moeda e o resultado for cara, qual é agora a probabilidade dela ser falsa?

- A probabilidade de ser falsa dado que o resultado foi cara é dada por:

$$P(F|C) = \frac{P(C|F)P(F)}{P(C)}$$

$$P(F|C) = \frac{1 \cdot 0.5}{0.75}$$

$$P(F|C) = \frac{0.5}{0.75}$$

$$P(F|C) = \frac{2}{3}$$

(iii) Se o professor lançar a moeda  $n$  vezes e obter  $n$  caras, qual é a probabilidade dela ser falsa? Estude o comportamento desta probabilidade para  $n$  grande.

- Pelo Teorema de Bayes, a probabilidade de ser falsa dado que o resultado foi cara  $n$  vezes é dada por:

$$P(F|C^n) = \frac{P(C^n|F)P(F)}{P(C^n)}$$

Onde  $P(C^n|F) = 1$ ,  $P(F) = P(H) = 0.5$  e  $P(C^n|H) = 0.5^n$

- Pela regra da probabilidade total, tem-se:

$$P(C^n) = P(C^n|F)P(F) + P(C^n|H)P(H)$$

$$P(C^n) = 1 \cdot 0.5 + 0.5^n \cdot 0.5$$

$$P(C^n) = 0.5 + 0.5^{n+1}$$

- Logo, substituindo:

$$P(F|C^n) = \frac{1 \cdot 0.5}{0.5 + 0.5^{n+1}}$$

$$P(F|C^n) = \frac{0.5}{0.5 + 0.5^{n+1}}$$

- Estudando o comportamento da probabilidade para  $n$  grande, tem-se:

$$P(F|C^n) = \frac{0.5}{0.5 + 0.5^{n+1}}$$

$$P(F|C^n) = \frac{0.5}{0.5 + 0}$$

$$P(F|C^n) = 1$$

**(iv) Se o professor lançar a moeda uma vez e obter cara, qual é a probabilidade do próximo lançamento ser cara?**

- A probabilidade do próximo lançamento ser cara dado que o resultado foi cara é dada por:

$$P(C|C) = \frac{P(C|F)P(F)}{P(C)}$$

$$P(C|C) = \frac{1 \cdot 0.5}{0.75}$$

$$P(C|C) = \frac{0.5}{0.75}$$

$$P(C|C) = \frac{2}{3}$$

**(v) Explique porque é falso neste contexto a afirmação “os dois lançamentos da moeda são independentes”, e explique qual seria a afirmação correta.**

- A probabilidade do segundo lançamento ser cara depende do resultado do primeiro lançamento. A afirmação correta seria “os dois lançamentos da moeda são condicionalmente independentes”, ou seja, a probabilidade do segundo lançamento ser cara dado que o primeiro foi cara é igual à probabilidade do segundo lançamento ser cara dado que o primeiro foi coroa.

## Questão 2

Seja  $y_1, y_2, \dots, y_n$  uma amostra da distribuição de Bernoulli com probabilidade de sucesso  $\theta$  e considere uma distribuição a priori uniforme para  $\theta$ .

(i) Ache a distribuição a posteriori de  $\theta$  e a sua média e variância.

- Entende-se que:

$$s = \sum_{i=1}^n y_i \sim \text{Binomial}(n, \theta)$$

$$P(\theta) \sim \text{Uniforme}(0, 1)$$

- Assim, a priori é dada por:

$$P(\theta) = \frac{1}{b-a} = \frac{1}{1-0} = 1, \quad 0 < \theta < 1$$

- A posteriori pode ser obtida por:

$$\theta|x \propto P(x|\theta)P(\theta)$$

$$\theta|x \propto \theta^s (1 - \theta)^{n-s} * 1$$

- Manipulando a expressão, tem-se:

$$\theta|x \propto \theta^{s+1-1} (1 - \theta)^{n-s+1-1}$$

- Assim, a posteriori é dada por:

$$\theta|x \sim \text{Beta}(s+1, n-s+1)$$

- Logo, pela distribuição, a média e a variância da posteriori são dadas por:

$$E(\theta|x) = \frac{s+1}{s+1+n-s+1} = \frac{s+1}{n+2}$$

$$\text{Var}(\theta|x) = \frac{(s+1)(n-s+1)}{(s+1+n-s+1)^2(s+1+n-s+1+1)} = \frac{(s+1)(n-s+1)}{(n+2)^2(n+3)}$$

(ii) Mostre que é possível expressar a esperança a posteriori de  $\theta$  da forma  $(1-w)E(\theta) + w\hat{\theta}$ , onde  $E(\theta)$  e  $\hat{\theta}$  são respectivamente a esperança a priori e a estimativa máximo verossímil de  $\theta$ , e interprete este resultado.

- A esperança a priori de  $\theta$  é dada por:

$$E(\theta) = \frac{1}{2}$$

- A estimativa máximo verossímil de  $\theta$  é dada por:

$$\hat{\theta} = \frac{s}{n}$$

- Assim, a esperança a posteriori de  $\theta$  pode ser expressa como:

$$E(\theta|x) = \frac{s+1}{n+2} = \frac{n}{n+2} \cdot \frac{s}{n} + \frac{2}{n+2} \cdot \frac{1}{2}$$

$$E(\theta|x) = \frac{n}{n+2} \hat{\theta} + \frac{2}{n+2} E(\theta)$$

- Sendo  $w = \frac{n}{n+2}$ , tem-se:

$$E(\theta|x) = (1-w)E(\theta) + w\hat{\theta}$$

**(iii) Se  $y_{n+1}$  é uma observação futura deste processo de Bernoulli, ache a distribuição preditiva  $p(y_{n+1}|y_1, \dots, y_n)$ .**

- A distribuição preditiva de  $y_{n+1}$  é dada por:

$$p(y_{n+1}|y_1, \dots, y_n) = \int p(y_{n+1}|\theta)p(\theta|y_1, \dots, y_n)d\theta$$

- Para  $y_{n+1} = 0$ , tem-se:

$$p(y_{n+1} = 0|y_1, \dots, y_n) = \int (1-\theta) \cdot p(\theta|y_1, \dots, y_n)d\theta$$

$$p(y_{n+1} = 0|y_1, \dots, y_n) = \frac{1}{B(s+1, n-s+1)} \int (1-\theta) \cdot \theta^s (1-\theta)^{n-s} d\theta$$

- A integral se assemelha à uma função Beta com parâmetros  $s+1$  e  $n-s+2$ , logo:

$$p(y_{n+1} = 0|y_1, \dots, y_n) = \frac{B(s+1, n-s+2)}{B(s+1, n-s+1)}$$

$$p(y_{n+1} = 0|y_1, \dots, y_n) = \frac{\Gamma(s+1)\Gamma(n-s+2)/\Gamma(n+3)}{\Gamma(s+1)\Gamma(n-s+1)/\Gamma(n+2)}$$

$$p(y_{n+1} = 0|y_1, \dots, y_n) = \frac{n-s+1}{n+2}$$

- Para  $y_{n+1} = 1$ , tem-se:

$$p(y_{n+1} = 1|y_1, \dots, y_n) = \int \theta \cdot p(\theta|y_1, \dots, y_n)d\theta$$

$$p(y_{n+1} = 1|y_1, \dots, y_n) = \frac{1}{B(s+1, n-s+1)} \int \theta \cdot \theta^s (1-\theta)^{n-s} d\theta$$

- A integral se assemelha à uma função Beta com parâmetros  $s+2$  e  $n-s+1$ , logo:

$$p(y_{n+1} = 1|y_1, \dots, y_n) = \frac{B(s+2, n-s+1)}{B(s+1, n-s+1)}$$

$$p(y_{n+1} = 1|y_1, \dots, y_n) = \frac{\Gamma(s+2)\Gamma(n-s+1)/\Gamma(n+3)}{\Gamma(s+1)\Gamma(n-s+1)/\Gamma(n+2)}$$

$$p(y_{n+1} = 1|y_1, \dots, y_n) = \frac{s+1}{n+2}$$

#### Questão 4

No exercício 2, calcule

##### (i) a estimativa bayesiana para Perda Quadrática

- A perda quadrática é dada por:

$$L(\theta, \hat{\theta}) = (\theta - \hat{\theta})^2$$

- Assim, a estimativa bayesiana para perda quadrática é dada por:

$$E[L(\theta, \hat{\theta})|x] = E[(\theta - \hat{\theta})^2|x]$$

$$E[L(\theta, \hat{\theta})|x] = E[\theta^2 - 2\theta\hat{\theta} + \hat{\theta}^2|x]$$

$$E[L(\theta, \hat{\theta})|x] = E[\theta^2|x] - 2E[\theta\hat{\theta}|x] + E[\hat{\theta}^2|x]$$

$$E[L(\theta, \hat{\theta})|x] = E[\theta^2|x] - 2\hat{\theta}E[\theta|x] + \hat{\theta}^2$$

$$E[L(\theta, \hat{\theta})|x] = Var(\theta|x) + E[\theta|x]^2 - 2\hat{\theta}E[\theta|x] + \hat{\theta}^2$$

$$E[L(\theta, \hat{\theta})|x] = \frac{(s+1)(n-s+1)}{(n+2)^2(n+3)} + \left(\frac{s+1}{n+2}\right)^2 - 2\hat{\theta}\frac{s+1}{n+2} + \hat{\theta}^2$$

- Isolando  $\hat{\theta}$ , tem-se:

$$\hat{\theta} = \frac{n}{n+2}\hat{\theta} + \frac{2}{n+2}\frac{1}{2}$$

$$\hat{\theta} = \frac{n}{n+2}\hat{\theta} + \frac{1}{n+2}$$

$$\hat{\theta} = \frac{n}{n+2}\frac{s}{n} + \frac{1}{n+2}$$

$$\hat{\theta} = \frac{s}{n+2} + \frac{1}{n+2}$$

$$\hat{\theta} = \frac{s+1}{n+2}$$

##### (ii) o limite da estimativa bayesiana para Perda Zero-Um quando $\epsilon \rightarrow \theta$ .

- A perda zero-um é dada por:

$$L(\theta, \hat{\theta}) = \begin{cases} 0, & se \quad \theta = \hat{\theta} \\ 1, & se \quad \theta \neq \hat{\theta} \end{cases}$$

- Assim, a estimativa bayesiana para perda zero-um é dada por:

$$E[L(\theta, \hat{\theta})|\underline{y}] = E[I(\theta \neq \hat{\theta})|\underline{y}]$$

$$E[L(\theta, \hat{\theta})|\underline{y}] = P(\theta \neq \hat{\theta}|\underline{y})$$

$$E[L(\theta, \hat{\theta})|\underline{y}] = 1 - P(\theta = \hat{\theta}|\underline{y})$$

**No caso especial que  $n = 12, s = \sum_{i=1}^{12} y_i = 9$ , calcule (iii) a estimativa bayesiana sob Perda Absoluta.**

- O objetivo é minimizar o valor esperado da perda absoluta, que é dada por:

$$L(\theta, \hat{\theta}) = |\theta - \hat{\theta}|$$

- O estimador de Bayes sob perda absoluta é a mediana da distribuição a posteriori de  $\theta$ . Nesse caso, a distribuição a posteriori de  $\theta$  é dada por:

$$\theta|\underline{y} \sim \text{Beta}(s + 1, n - s + 1)$$

- No caso em que  $s = 9$  e  $n = 12$  e  $\underline{y}$  o vetor de observações  $(y_1, y_2, \dots, y_{12})$ , tem-se:

$$\theta|\underline{y} \sim \text{Beta}(10, 4)$$

- Utilizando o R, é possível aproximar a mediana da distribuição a posteriori de  $\theta$  de modo que:

```
qbeta(0.5, 10, 4)
```

```
[1] 0.7247242
```

- Logo, a estimativa bayesiana sob perda absoluta é dada por:

$$\hat{\theta} = \text{Mediana} = 0.725$$

**(iv) o intervalo HPD com credibilidade 0.99.**

- O intervalo HPD é dado pelos limites  $a$  e  $b$  tais que:

$$\int_a^b f(\theta|x) d\theta = 0.99$$

- Onde  $f(\theta|x)$  é a distribuição a posteriori de  $\theta$ .
- Assim,

$$HPD = [\theta_{(1-\alpha)/2}, \theta_{(1+\alpha)/2}]$$

$$HPD = [\theta_{0.005}, \theta_{0.995}]$$

- Com  $s = 9$  e  $n = 12$ , tem-se:



$\theta|x \sim \text{Beta}(10, 4)$

- Logo, o intervalo é:

```
qgamma(c(0.005, 0.995), 10, 4)
```

```
[1] 0.9292305 4.9996058
```

## Questão 8

Suponha que  $(x_1, x_2, x_3)$  dado  $p_1, p_2, p_3$  segue uma distribuição Multinomial com parâmetros  $n$  e  $(p_1, p_2, p_3)$ , onde  $p_i \geq 0$  e  $p_1 + p_2 + p_3 = 1$ , e que, a priori,  $(p_1, p_2, p_3)$  segue uma distribuição de Dirichlet com parâmetros  $(\alpha_1, \alpha_2, \alpha_3)$ .

(i) Ache a distribuição a posteriori de  $p_1, p_2, p_3$  e as distribuições a posteriori marginais de  $p_i$  ( $i = 1, 2, 3$ )

- Entende-se que:

$$(x_1, x_2, x_3) \sim \text{Multinomial}(n, (p_1, p_2, p_3))$$

$$P(p_1, p_2, p_3) \sim \text{Dirichlet}(\alpha_1, \alpha_2, \alpha_3)$$

- Assim, a priori é dada por:

$$P(p_1, p_2, p_3) = \frac{1}{B(\alpha_1, \alpha_2, \alpha_3)} p_1^{\alpha_1-1} p_2^{\alpha_2-1} p_3^{\alpha_3-1}$$

- A posteriori pode ser obtida por:

$$p_1, p_2, p_3 | x \propto P(x | p_1, p_2, p_3) P(p_1, p_2, p_3)$$

$$p_1, p_2, p_3 | x \propto p_1^{x_1} p_2^{x_2} p_3^{x_3} p_1^{\alpha_1-1} p_2^{\alpha_2-1} p_3^{\alpha_3-1}$$

$$p_1, p_2, p_3 | x \propto p_1^{x_1+\alpha_1-1} p_2^{x_2+\alpha_2-1} p_3^{x_3+\alpha_3-1}$$

- Assim, a posteriori é dada por:

$$p_1, p_2, p_3 | x \sim \text{Dirichlet}(x_1 + \alpha_1, x_2 + \alpha_2, x_3 + \alpha_3)$$

- As distribuições a posteriori marginais de  $p_i$  são dadas por:

$$p_i|x = \int p_1, p_2, p_3|x dp_1 dp_2 dp_3$$

$$p_i|x = \int p_1, p_2, p_3|x \prod_{j \neq i} dp_j$$

$$p_i|x = \int p_1^{x_1+\alpha_1-1} p_2^{x_2+\alpha_2-1} p_3^{x_3+\alpha_3-1} dp_1 dp_2 dp_3$$

$$p_i|x = \int p_i^{x_i+\alpha_i-1} (1-p_i)^{n-x_i+\alpha_{-i}-1} dp_i$$

- Logo, é possível observar que:

$$p_i|x = \frac{B(x_i+\alpha_i, n-x_i+\alpha_{-i})}{B(\alpha_i, \alpha_{-i})}$$

- Então, as distribuições a posteriori marginais de  $p_i$  são dadas por:

$$p_i|x \sim \text{Beta}(x_i + \alpha_i, n - x_i + \alpha_{-i})$$

**(ii) Calcule as estimativas bayesianas de  $p_i$  e de  $p_j - p_i$  sob Perda Quadrática ( $i, j = 1, 2, 3, i \neq j$ ).**

- As estimativas bayesianas de  $p_i$  sob perda quadrática são dadas por:

$$E[L(p_i, \hat{p}_i)|x_i] = \frac{\alpha_i + x_i}{\alpha_1 + x_1 + \alpha_2 + x_2 + \alpha_3 + x_3}$$

- Logo, as estimativas bayesianas de  $p_j - p_i$  sob perda quadrática são dadas por:

$$E[L(p_j - p_i, \hat{p}_j - \hat{p}_i)|x] = \frac{\alpha_j + x_j}{\alpha_1 + x_1 + \alpha_2 + x_2 + \alpha_3 + x_3} - \frac{\alpha_i + x_i}{\alpha_1 + x_1 + \alpha_2 + x_2 + \alpha_3 + x_3}$$

## Questão 11

É conhecido que 25% dos pacientes de um certo grupo que sofrem de enxaqueca melhoram após duas horas de serem tratados com um placebo. Para verificar se uma droga nova é melhor que o placebo,  $n = 20$  pacientes foram tratados com o placebo e verificou-se que após duas horas  $s = 8$  deles relataram ter melhorado. Seja  $\theta$  a probabilidade de um paciente tratado com a droga nova melhorar após duas horas.

(i) Especifique a hipótese nula  $H_0$  e a alternativa  $H_1$ ;

$$\begin{cases} H_0 : \theta \leq 0.25 \\ H_1 : \theta > 0.25 \end{cases}$$

(ii) Usando a distribuição a priori “não informativa”  $\theta \sim \text{Uniforme}(0, 1)$ , calcule as chances relativas a priori e a posteriori de  $H_1$  e o correspondente Fator de Bayes;

- Entende-se que:

$$\sum X_i \sim^{iid} \text{Binomial}(20, \theta)$$

$$P(\theta) \sim \text{Uniforme}(0, 1)$$

- Assim, a priori é dada por:

$$P(\theta) = \frac{1}{b-a} = \frac{1}{1-0} = 1, \quad 0 < \theta < 1$$

- Logo, as probabilidades a priori são dadas por:

$$P(H_0) = P(\theta \leq 0.25) = \int_0^{0.25} 1d\theta = 0.25$$

$$P(H_1) = P(\theta > 0.25) = \int_{0.25}^1 1d\theta = 0.75$$

- Odds a priori

$$\text{odds}(\theta \leq 0.25) = \frac{P(\theta \leq 0.25)}{P(\theta > 0.25)} = \frac{0.25}{0.75} = \frac{1}{3}$$

$$\text{odds}(\theta > 0.25) = \frac{P(\theta > 0.25)}{P(\theta \leq 0.25)} = \frac{0.75}{0.25} = 3$$

- Pode-se concluir assim que a priori a chance de  $H_1$  é 3 vezes maior que a chance de  $H_0$ .

- Sabe-se que:

$$\theta|x \propto P(x|\theta)P(\theta)$$

$$\theta|x \propto \theta^s(1-\theta)^{n-s} * 1$$

- Manipulando a expressão, tem-se:

$$\theta|x \propto \theta^{s+1-1}(1-\theta)^{n-s+1-1}$$

- Assim, a posteriori é dada por:

$$\theta|x \sim \text{Beta}(s+1, n-s+1)$$

- Com  $s = 8$  e  $n = 20$ , tem-se:

$$\theta|x \sim \text{Beta}(9, 13)$$

- Logo, as probabilidades a posteriori são dadas por:

$$P(H_0|x) = P(\theta \leq 0.25|s = 8)$$

```
ph0<-round(pbeta(0.25, 9, 13),3)
ph0
```

```
[1] 0.056
```

$$P(H_1|x) = P(\theta > 0.25|s = 8)$$

```
ph1<-round(1 - pbeta(0.25, 9, 13),3)
ph1
```

[1] 0.944

- Odds a posteriori

$$odds(\theta \leq 0.25) = 0.056 / 0.944 = 0.059$$

$$odds(\theta > 0.25) = 0.944 / 0.056 = 16.857$$

- Pode-se concluir assim que a posteriori a chance de  $H_1$  é 16.86 vezes maior que a chance de  $H_0$ .
- Fator de Bayes

$$\beta_{1,0} = \frac{odds(\theta_1|x)}{odds(\theta_1)} = 16.8/3 = 5.6 \text{ em favor de } H_1.$$

$$\beta_{0,1} = \frac{odds(\theta_0|x)}{odds(\theta_0)} = 3/16.8 = 0.18 \text{ em favor de } H_0.$$

- Assim, a interpretação do Fator de Bayes é que a evidência a favor de  $H_1$  é 5.6 vezes mais forte que a evidência a favor de  $H_0$ .

(iii) Seja  $d = 1$  a decisão de rejeitar  $H_0$  e  $d = 0$  a de não rejeitar. Considere a função de perda de Neyman para a qual é 5 vezes mais custoso rejeitar  $H_0$  quando ela é verdadeira do que não rejeitar quando ela é falsa [isto é,  $L(d = 1, \theta \in H_0) = 5L(d = 0, \theta \notin H_0)$ ,  $L(d = 1, \theta \notin H_0) = L(d = 0, \theta \in H_0) = 0$ ]. Calcule a decisão ótima a posteriori;

- Entende-se que:

$$L(d = 1, \theta \in H_0) = L(d = 0, \theta \notin H_0) = 5$$

$$L(d = 1, \theta \notin H_0) = L(d = 0, \theta \in H_0) = 0$$

- A função de perda de Neyman é dada por:

$$a = L(d = 1, \theta < 0.25) = 5 \cdot L(d = 0, \theta > 0.25) = 5b$$

- Assim, a decisão ótima a posteriori é dada por:

$$P(\theta \leq 0.25|x) > \frac{a}{a+b}$$

$$P(\theta \leq 0.25|x) > \frac{5}{5+1}$$

$$P(\theta \leq 0.25|x) > \frac{5}{6}$$

$$P(\theta \leq 0.25|x) > 0.833$$

(iv) É razoável chamar essa distribuição a priori de "não informativa" nesse problema? Se a sua resposta for negativa, sugira uma outra distribuição a priori e refaça os cálculos anteriores.

- É razoável, mas é necessário levar em conta que ao assumir uma distribuição a priori uniforme, supõe-se que todas as probabilidades são igualmente prováveis, favorecendo a hipótese alternativa. Conforme o item (ii), a chance de  $H_1$  é 3 vezes mais forte que a chance de  $H_0$ . Assim, uma possibilidade para equilibrar as hipóteses seria assumir uma distribuição a priori Beta(1,3). Nesse caso, a priori é dada por:

$$P(\theta) = \frac{1}{B(1,3)}\theta^{1-1}(1-\theta)^{3-1}$$

$$P(\theta) = 3(1-\theta)^2$$

- Logo, as probabilidades a priori são dadas por:

$$P(H_0) = P(\theta \leq 0.25) = \int_0^{0.25} 3(1-\theta)^2 d\theta = 0.578$$

$$P(H_1) = P(\theta > 0.25) = \int_{0.25}^1 3(1-\theta)^2 d\theta = 0.422$$

- Odds a priori

$$odds(\theta \leq 0.25) = \frac{P(\theta \leq 0.25)}{P(\theta > 0.25)} = \frac{0.578}{0.422} = 1.37$$

$$odds(\theta > 0.25) = \frac{P(\theta > 0.25)}{P(\theta \leq 0.25)} = \frac{0.422}{0.578} = 0.73$$

- Pode-se concluir assim que a priori a chance de  $H_0$  é 1.37 vezes maior que a chance de  $H_1$ .
- Sabe-se que:

$$\theta|x \sim Beta(s+1, n-s+1)$$

- Com  $s = 8$  e  $n = 20$ , tem-se:

$$\theta|x \sim Beta(9, 13)$$

- Logo, as probabilidades a posteriori são dadas por:

$$P(H_0|x) = P(\theta \leq 0.25|s = 8)$$

```
ph0<-round(pbeta(0.25, 9, 13),3)
ph0
```

```
[1] 0.056
```

$$P(H_1|x) = P(\theta > 0.25|s = 8)$$

```
ph1<-round(1 - pbeta(0.25, 9, 13),3)
ph1
```

```
[1] 0.944
```

- Odds a posteriori

$$\text{odds}(\theta \leq 0.25) = 0.056 / 0.944 = 0.059$$

$$\text{odds}(\theta > 0.25) = 0.944 / 0.056 = 16.857$$

- Pode-se concluir assim que a posteriori a chance de  $H_1$  é 16.857 vezes maior que a chance de  $H_0$ .
- Fator de Bayes

$$\beta_{1,0} = \frac{\text{odds}(\theta_1|x)}{\text{odds}(\theta_1)} = 16.8/0.73 = 23.01 \text{ em favor de } H_1.$$

$$\beta_{0,1} = \frac{\text{odds}(\theta_0|x)}{\text{odds}(\theta_0)} = 0.059/1.37 = 0.043 \text{ em favor de } H_0.$$

## Lista 3.1

### Questão 1

1. Seja  $x_1, x_2, \dots, x_n$  uma amostra da distribuição de Poisson com média  $\theta$ , e considere a priori que  $\theta$  tem uma distribuição Gama com parâmetros  $\alpha$  e  $\beta$  (ou seja, com média  $\frac{\alpha}{\beta}$  e variância  $\frac{\alpha}{\beta^2}$ ).

(i) Ache a distribuição a posteriori de  $\theta$  e sua média e variância.

- Entende-se que:

$$x_i \sim \text{Poisson}(\theta)$$

$$\theta \sim \text{Gama}(\alpha, \beta)$$

- Assim, a priori é dada por:

$$P(\theta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta}$$

- A posteriori pode ser obtida por:

$$\theta|x \propto P(x|\theta)P(\theta)$$

$$\theta|x \propto \theta^{\sum x_i} e^{-n\theta} \theta^{\alpha-1} e^{-\beta\theta}$$

$$\theta|x \propto \theta^{\sum x_i + \alpha - 1} e^{-(n+\beta)\theta}$$

- Assim, a posteriori é dada por:

$$\theta|x \sim \text{Gama}(\sum x_i + \alpha, n + \beta)$$

- Logo, a média e a variância da posteriori são dadas por:

$$E(\theta|x) = \frac{\sum x_i + \alpha}{n + \beta}$$

$$\text{Var}(\theta|x) = \frac{\sum x_i + \alpha}{(n + \beta)^2}$$

**(ii) Mostre que é possível expressar a esperança a posteriori de  $\theta$  da forma  $w\bar{x} + (1-w)\frac{\alpha}{\beta}$ , e interprete este resultado.**

- A esperança a priori de  $\theta$  é dada por:

$$E(\theta) = \frac{\alpha}{\beta}$$

- Assim, a esperança a posteriori de  $\theta$  pode ser expressa como:

$$E(\theta|x) = \frac{\sum x_i + \alpha}{n + \beta} = \frac{n}{n + \beta} \frac{\sum x_i}{n} + \frac{\beta}{n + \beta} \frac{\alpha}{\beta}$$

$$E(\theta|x) = \frac{n}{n + \beta} \bar{x} + \frac{\beta}{n + \beta} \frac{\alpha}{\beta}$$

- Sendo  $w = \frac{n}{n + \beta}$ , tem-se:

$$E(\theta|x) = w\bar{x} + (1-w)\frac{\alpha}{\beta}$$

- Assim, a interpretação deste resultado é que a esperança a posteriori de  $\theta$  é uma combinação linear entre a média amostral  $\bar{x}$  e a média a priori  $\frac{\alpha}{\beta}$ , onde o peso  $w$  é dado pela razão entre o tamanho amostral  $n$  e a soma do tamanho amostral com o parâmetro  $\beta$ .

**(iii) O que acontece na parte (ii) quando  $\beta$  é grande com  $\frac{\alpha}{\beta}$  fixo? Interprete!**

$$\lim_{\beta \rightarrow \infty} w = \lim_{\beta \rightarrow \infty} \frac{n}{n + \beta} = \frac{n}{\beta} = 0$$

- Logo, se  $\beta$  é grande, o peso  $w$  tende a 0, de forma que a esperança a posteriori de  $\theta$  se aproxima da média a priori  $\frac{\alpha}{\beta}$ :

$$E(\theta|x) = w\bar{x} + (1-w)\frac{\alpha}{\beta}$$

$$E(\theta|x) = 0 + (1-0)\frac{\alpha}{\beta}$$

$$E(\theta|x) = \frac{\alpha}{\beta}$$

- Assim, a interpretação é que a medida que o parâmetro  $\beta$  aumenta, a influência da informação amostral diminui e a estimativa se aproxima da média a priori  $\frac{\alpha}{\beta}$ .

**(iv) Mostre que existe um número  $c$  tal que a variância a posteriori é maior do que a variância a priori sempre que  $\bar{x} > c$ , ache  $c$  e interprete este resultado.**

- A variância a priori de  $\theta$  é dada por:

$$Var(\theta) = \frac{\alpha}{\beta^2}$$

- Assim, a variância a posteriori de  $\theta$  é dada por:

$$Var(\theta|x) = \frac{\sum x_i + \alpha}{(n+\beta)^2}$$

- Para que a variância a posteriori seja maior que a variância a priori, é necessário que:

$$\frac{\sum x_i + \alpha}{(n+\beta)^2} > \frac{\alpha}{\beta^2}$$

$$\frac{\sum x_i + \alpha}{n+\beta} > \frac{\alpha}{\beta}$$

$$\frac{\sum x_i}{n} + \frac{\alpha}{n+\beta} > \frac{\alpha}{\beta}$$

$$\frac{\sum x_i}{n} > \frac{\alpha}{\beta} - \frac{\alpha}{n+\beta}$$

$$\frac{\sum x_i}{n} > \frac{\alpha}{\beta} - \frac{\alpha}{n+\beta}$$

$$\frac{\sum x_i}{n} > \frac{\alpha(n+\beta) - \alpha\beta}{\beta(n+\beta)}$$

$$\frac{\sum x_i}{n} > \frac{\alpha n}{\beta(n+\beta)}$$

$$\frac{\sum x_i}{n} > \frac{\alpha}{\beta} \cdot \frac{n}{n+\beta}$$

- Assim, o número  $c$  é dado por:

$$c = \frac{\alpha}{\beta}$$

- A interpretação deste resultado é que a variância a posteriori de  $\theta$  é maior que a variância a priori sempre que a média amostral  $\bar{x}$  for maior que a razão entre os parâmetros  $\alpha$  e  $\beta$ , ou seja, a variância a posteriori é maior que a variância a priori quando a média amostral é maior que a média a priori.



### Questão 3

Seja  $x_1, x_2, \dots, x_n$  uma amostra da distribuição de Poisson com média  $\theta$ , e considere a priori que  $\theta$  tem uma distribuição Gama com parâmetros  $\alpha = 1$  e  $\beta = 1$ . Ache:

(a) a estimativa bayesiana de  $\theta$  no caso de perda quadrática

- Para um priori Gama com  $\alpha = 1$  e  $\beta = 1$ , tem-se uma posteriori:

$$\theta|x \sim \text{Gama}(\sum x_i + 1, n + 1)$$

- Assim, a estimativa bayesiana de  $\theta$  no caso de perda quadrática é dada por:

$$\hat{\theta} = \frac{\sum x_i + 1}{n + 1}$$

(b) o limite da estimativa bayesiana sob perda zero-um quando  $\epsilon \rightarrow 0$ .

- A perda zero-um é dada por:

$$\hat{\theta} = \frac{\sum x_i + 1 - 1}{n + 1}$$

$$\hat{\theta} = \frac{\sum x_i}{n + 1}$$

Para o caso  $n = 10$  e  $\bar{x} = 1.55$ , ache: (c) a estimativa bayesiana sob perda absoluta

- Para  $n=10$  e  $\bar{x} = 1.55$ , a estimativa bayesiana sob perda absoluta é dada por:

$$\alpha = \sum x_i + 1 = 10 \cdot 1.55 + 1 = 16.5$$

$$\beta = n + 1 = 10 + 1 = 11$$

- Logo, a estimativa bayesiana sob perda absoluta é dada pela mediana da distribuição a posteriori de  $\theta$ :

```
qgamma(0.5, 16.5, 11)
```

[1] 1.469808

(d) o intervalo HPD para  $\theta$  com nível 95%

- O intervalo HPD é dado pelos limites  $a$  e  $b$  tais que:

$$\int_a^b f(\theta|x) d\theta = 0.95$$

- Onde  $f(\theta|x)$  é a distribuição a posteriori de  $\theta$ ,  $\text{Gamma}(16.5, 11)$ .

```
qgamma(c(0.025, 0.975), 16.5, 11)
```

[1] 0.8657573 2.3056855

### Questão 5

Seja  $x_1, x_2, \dots, x_n$  uma amostra da distribuição Normal com média  $\mu$  e variância  $\phi^{-1}$  conhecida, e considere a distribuição a priori  $\mu \sim N(\mu_0, \tau^{-1})$ .

(i) Ache a distribuição a posteriori de  $\mu$ .

- Entende-se que:

$$x_i \sim \text{Normal}(\mu, \phi^{-1})$$

$$\mu \sim \text{Normal}(\mu_0, \tau^{-1})$$

- Assim, a priori é dada por:

$$P(\mu) = \frac{1}{\sqrt{2\pi\tau}} e^{-\frac{1}{2\tau}(\mu-\mu_0)^2}$$

- A posteriori pode ser obtida por:

$$\mu|x \propto P(x|\mu)P(\mu)$$

$$\mu|x \propto \prod_{i=1}^n \frac{1}{\sqrt{2\pi\phi^{-1}}} e^{-\frac{1}{2\phi^{-1}}(x_i-\mu)^2} \cdot \frac{1}{\sqrt{2\pi\tau}} e^{-\frac{1}{2\tau}(\mu-\mu_0)^2}$$

$$\mu|x \propto e^{-\frac{1}{2\phi^{-1}} \sum_{i=1}^n (x_i-\mu)^2} \cdot e^{-\frac{1}{2\tau}(\mu-\mu_0)^2}$$

$$\mu|x \propto e^{-\frac{1}{2\phi^{-1}} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2)} \cdot e^{-\frac{1}{2\tau}(\mu^2 - 2\mu\mu_0 + \mu_0^2)}$$

$$\mu|x \propto e^{-\frac{1}{2\phi^{-1}} \sum_{i=1}^n (x_i^2 - 2x_i\mu + \mu^2) - \frac{1}{2\tau}(\mu^2 - 2\mu\mu_0 + \mu_0^2)}$$

- Logo,

$$\mu|x \sim \text{Normal}\left(\frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}, \frac{1}{n/\phi + 1/\tau}\right)$$

(ii) Mostre que é possível expressar a esperança a posteriori de  $\mu$  da forma  $w\bar{x} + (1-w)\mu_0$ , e interprete este resultado.

- A esperança a priori de  $\mu$  é dada por:

$$E(\mu) = \mu_0$$

- Assim, a esperança a posteriori de  $\mu$  pode ser expressa como:

$$E(\mu|x) = \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}$$

$$E(\mu|x) = \frac{n\mu_0 + \sum x_i}{n + \phi/\tau}$$

$$E(\mu|x) = \frac{n}{n + \phi/\tau} \bar{x} + \frac{\phi/\tau}{n + \phi/\tau} \mu_0$$

- Sendo  $w = \frac{n}{n + \phi/\tau}$ , tem-se:

$$E(\mu|x) = w\bar{x} + (1 - w)\mu_0$$

(iii) Se  $\bar{x}_m$  é a média de  $m$  observações futuras  $x_{n+1}, \dots, x_{n+m}$ , condicionalmente independentes de  $x_1, \dots, x_n$ , ache a distribuição preditiva  $p(\bar{x}_m|x_1, \dots, x_n)$ .

- Entende-se que:

$$\bar{x}_m = \frac{\sum_{i=n+1}^{n+m} x_i}{m}$$

- Assim, a distribuição preditiva é dada por:

$$p(\bar{x}_m|x) = \int p(\bar{x}_m|\mu)p(\mu|x)d\mu$$

$$p(\bar{x}_m|x) = \int Normal(\bar{x}_m|\mu, \phi^{-1}/m) Normal(\mu|\frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}, \frac{1}{n/\phi + 1/\tau})d\mu$$

$$p(\bar{x}_m|x) = \int \frac{1}{\sqrt{2\pi\phi^{-1}/m}} e^{-\frac{1}{2\phi^{-1}/m}(\bar{x}_m - \mu)^2} \cdot \frac{1}{\sqrt{2\pi \frac{1}{n/\phi + 1/\tau}}} e^{-\frac{1}{2 \frac{1}{n/\phi + 1/\tau}}(\mu - \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau})^2} d\mu$$

$$p(\bar{x}_m|x) = \int \frac{1}{\sqrt{2\pi\phi^{-1}/m}} e^{-\frac{1}{2\phi^{-1}/m}(\bar{x}_m - \mu)^2} \cdot \frac{1}{\sqrt{2\pi \frac{1}{n/\phi + 1/\tau}}} e^{-\frac{1}{2 \frac{1}{n/\phi + 1/\tau}}(\mu - \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau})^2} d\mu$$

- Assim,

$$p(\bar{x}_m|x) \sim Normal(\bar{x}_m|\frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}, \frac{1}{n/\phi + 1/\tau} + \phi^{-1}/m)$$

(iv) Discuta o que acontece com os resultados anteriores quando a distribuição a priori  $p(\mu) \propto 1$  (ou seja, o caso limite quando  $\tau \rightarrow 0$ ).

- Quando a distribuição a priori é uniforme, a informação a priori é desconsiderada e a estimativa é baseada apenas na informação amostral. Assim, a média a posteriori de  $\mu$  é dada pela média amostral  $\bar{x}$ , a variância a posteriori de  $\mu$  é dada pela variância amostral  $\phi^{-1}/n$  e a distribuição preditiva é dada por:

$$p(\bar{x}_m|x) \sim Normal(\bar{x}_m|\bar{x}, \phi^{-1}/n + \phi^{-1}/m)$$

- Assim, a interpretação é que a medida que o parâmetro  $\tau$  tende a zero, a influência da informação a priori diminui e a estimativa se aproxima da média amostral, a variância a posteriori de  $\mu$  diminui e a distribuição preditiva é dada pela média amostral e pela variância amostral.

## Questão 6

Seja  $x_1, x_2, \dots, x_n$  uma amostra da distribuição Normal com média  $\mu$  e variância  $\phi^{-1}$  conhecida, e considere a distribuição a priori  $\mu \sim N(\mu_0, \tau^{-1})$ .

(a): Ache o estimador bayesiano de  $\mu$  no caso de

(i) perda quadrática ( $L(\hat{\mu}, \mu) = (\hat{\mu} - \mu)^2$ ),

- Para encontrar  $\hat{\mu}$  sob perda quadrática, é necessário minimizar a perda esperada:

$$E[L(\hat{\mu}, \mu)|x] = E[(\hat{\mu} - \mu)^2|x]$$

$$E[L(\hat{\mu}, \mu)|x] = E[\hat{\mu}^2 - 2\hat{\mu}\mu + \mu^2|x]$$

$$E[L(\hat{\mu}, \mu)|x] = E[\hat{\mu}^2|x] - 2E[\hat{\mu}\mu|x] + E[\mu^2|x]$$

$$E[L(\hat{\mu}, \mu)|x] = Var(\hat{\mu}|x) + E[\hat{\mu}|x]^2 - 2\mu E[\hat{\mu}|x] + \mu^2$$

$$E[L(\hat{\mu}, \mu)|x] = \frac{1}{n/\phi+1/\tau} + E[\hat{\mu}|x]^2 - 2\mu E[\hat{\mu}|x] + \mu^2$$

- Assim, a estimativa bayesiana de  $\mu$  sob perda quadrática é dada por:

$$\hat{\mu} = E[\mu|x] = \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}$$

(ii) perda absoluta ( $L(\hat{\mu}, \mu) = |\hat{\mu} - \mu|$ )

- Para encontrar  $\hat{\mu}$  sob perda absoluta, o processo é similar:

$$E[L(\hat{\mu}, \mu)|x] = E[|\hat{\mu} - \mu|x]$$

- Logo,

$$\hat{\mu} = E[\mu|x] = \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}$$

(iii) perda zero-um ( $L(\hat{\mu}, \mu) = I(|\hat{\mu} - \mu| \geq \epsilon)$ ).

- Para encontrar  $\hat{\mu}$  sob perda zero-um, o processo também é similar:

$$E[L(\hat{\mu}, \mu)|x] = E[I(|\hat{\mu} - \mu| \geq \epsilon)|x]$$

- Assim,

$$\hat{\mu} = E[\mu|x] = \frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}$$

(b): Ache o intervalo HPD para  $\mu$  com nível  $100(1 - \alpha)\%$

- O intervalo HPD é dado pelos limites  $a$  e  $b$  tais que:

$$\int_a^b f(\theta|x)d\theta = 100(1 - \alpha)\%$$

- Onde  $f(\theta|x)$  é a distribuição a posteriori de  $\theta$ . Nesse caso:

$$\mu|x \sim \text{Normal}\left(\frac{\sum x_i/\phi + \mu_0/\tau}{n/\phi + 1/\tau}, \frac{1}{n/\phi + 1/\tau}\right)$$

- Assim, com  $n = 10$ ,  $\bar{x} = 1.55$ ,  $\mu_0 = 1$ ,  $\tau = 1$  e  $\phi = 1$ , o intervalo HPD para  $\mu$  com nível  $100(1 - \alpha)\%$  é dado por:

```
arg_mu = (1 * (10*1.55) + 1 * 1) / (1 * 10 + 1)
arg_sd = 1/(sqrt(1 * 10 + 1))

qnorm(c(0.025,0.975), arg_mu, arg_sd)
```

[1] 0.9090486 2.0909514

## Lista 3.2

### Questão 1

Considere o modelo  $X \sim \text{Uniforme}(\theta, \theta + 1)$  ( $-\infty < \theta < \infty$ ).

(a) Mostre que  $\theta$  é um parâmetro de locação.

- Para mostrar que  $\theta$  é um parâmetro de locação, é necessário verificar se a distribuição é invariante por translação, ou seja, se  $Y = X - \theta$  tem a mesma distribuição que  $X$ .
- A densidade de probabilidade de  $X$  é dada por:

$$f(x|\theta) = \begin{cases} 1, & \text{se } \theta \leq x \leq (\theta + 1) \\ 0, & \text{caso contrário} \end{cases}$$

- Logo, ao fazermos a transformação  $Y = X - \theta$ , o novo modelo é  $Y \sim \text{Uniforme}(0, 1)$ .

$$P(Y) = \int_{\theta}^{\theta+1} \frac{1}{1} dx = 1$$

- Observa-se que  $X$  depende de  $\theta$  apenas como uma translação. Mesmo se adicionarmos ou subtrairmos uma constante a  $\theta$ , a distribuição se desloca, mas não perde sua forma. Portanto, podemos concluir que  $\theta$  é um parâmetro de locação.

**(b) Dada a priori não informativa usual para o modelo de locação,  $p(\theta) \propto 1$  e uma amostra aleatória  $X_1, \dots, X_n$  do modelo acima, discuta a propriedade da distribuição a posteriori.**

- A priori não informativa usual para o modelo de locação é dada por:

$$p(\theta) \propto 1$$

- Assim, a distribuição a posteriori de  $\theta$  é dada por:

$$\theta|x \propto P(x|\theta)P(\theta)$$

$$\theta|x \propto \prod_{i=1}^n \frac{1}{1} \cdot 1$$

$$\theta|x \propto 1$$

- A função de verossimilhança é dada por:

$$L(\theta|x) = \prod_{i=1}^n 1, \text{ se } \theta \leq x \leq (\theta + 1)$$

- Isso implica que o valor de  $\theta$  deve ser pequeno o suficiente para que  $X_1$  (menor valor de  $X$ ) seja maior ou igual a  $\theta$  e grande o suficiente para que  $X_n$  (ou o maior valor de  $X$ ) seja menor ou igual a  $\theta + 1$ . Duas condições devem ser satisfeitas:

$$\begin{cases} \theta \leq \min(X_1, X_2, \dots, X_n) \\ \theta + 1 \geq \max(X_1, X_2, \dots, X_n) \end{cases}$$

Portanto,

- A posteriori é dada por:

$$p(\theta|x) \propto L(\theta|x)p(\theta) = 1$$

$$\text{se } \min(X_1, X_2, \dots, X_n) \leq \theta \leq \max(X_1, X_2, \dots, X_n)$$

- Pode se concluir então que a posteriori é dada por:

$$\theta|x \sim U[\min(X_1, \dots, X_n), \max(X_1, \dots, X_n)]$$

**(c) Na situação da parte (b), ache:**

**(i) os estimadores bayesianos sob Perda Quadrática e sob Perda Absoluta;**

- O estimador bayesiano de  $\theta$  sob perda quadrática é dado por:

$$\hat{\theta}_q = E[\theta|x] = \int \theta p(\theta|x) d\theta$$

- O estimador bayesiano de  $\theta$  sob perda absoluta é dado por:

$$\hat{\theta}_a = \text{mediana}(\theta|x)$$

- Sabendo que a distribuição a posteriori de  $\theta$  é dada por  $\theta|x \sim U[\min(X_1, \dots, X_n), \max(X_1, \dots, X_n)]$ , tem-se que:

$$\hat{\theta}_q = \hat{\theta}_a = \frac{\min(X_1, \dots, X_n) + \max(X_1, \dots, X_n)}{2}$$

**(ii) O intervalo HPD para  $\theta$  com credibilidade  $100(1 - \alpha)\%$**

- Nesse caso, o intervalo HPD será o intervalo central da distribuição de  $\theta$ . Assim,

$$\text{Limite inferior: } \min(X_1, \dots, X_n) - \frac{\alpha}{2} \cdot [\min(X_1, \dots, X_n) - (\max(X_1, \dots, X_n) - 1)]$$

$$\text{Limite superior: } \max(X_1, \dots, X_n) - \frac{\alpha}{2} \cdot [\max(X_1, \dots, X_n) - (\min(X_1, \dots, X_n) + 1)]$$

- Ou seja, o intervalo HPD para  $\theta$  com credibilidade  $100(1 - \alpha)\%$  é dado por:

$$HPD = [\max(X_1, \dots, X_n) - 1 + \frac{\alpha}{2}, \min(X_1, \dots, X_n) - \frac{\alpha}{2}]$$

- Considerando que é uma distribuição uniforme, se soubessemos os valores de  $X_1, \dots, X_n$ , poderíamos calcular no R:

```
qunif(alpha/2, min(x), max(x))
```

```
qunif(1-alpha/2, min(x), max(x))
```

**(iii) A probabilidade a posteriori do evento  $\theta > \theta_0$ .**

Se  $\theta_0 < \max(X_1, \dots, X_n) - 1$ , então  $P(\theta > \theta_0) = 1$ .

Se  $\theta_0 > \max(X_1, \dots, X_n)$ , então  $P(\theta > \theta_0) = 0$ .

Se  $\theta_0$  estiver entre  $\min(X_1, \dots, X_n)$  e  $\max(X_1, \dots, X_n) - 1$ , então  $P(\theta > \theta_0) = 1 - \frac{\theta_0 - \min(X_1, \dots, X_n)}{\max(X_1, \dots, X_n) - \min(X_1, \dots, X_n) + 1}$

## Questão 2

Considere o modelo  $X \sim \text{Uniforme}(0, \theta)$  ( $0 < \theta < \infty$ ).

**(a) Mostre que  $\sigma = \theta^{-1}$  é um parâmetro de escala.**

- Temos que um parâmetro de escala afeta o tamanho ou a amplitude da distribuição, sem alterar sua forma. Se  $\sigma$  é um parâmetro de escala, então multiplicar  $X$  por uma constante  $c$  deve alterar  $\sigma$  de forma proporcional a  $c$ .
- Fazendo uma transformação de variável  $Y = cX$ , onde  $c$  é uma constante, tem-se:

$$Y \sim \text{Uniforme}(0, c\theta)$$

- Isso mostra que o parâmetro  $\theta$  foi escalado por uma constante  $c$ . Assim, tem-se:

$$\sigma_Y = c\theta^{-1} = \frac{1}{c} \cdot \sigma$$

- $\sigma$  foi escalado por uma constante  $1/c$ , o que mostra que  $\sigma = \theta^{-1}$  é um parâmetro de escala.

**(b) Dada a priori não informativa usual para o modelo de escala,  $p(\sigma) \propto \sigma^{-1}$  e uma amostra aleatória  $X_1, \dots, X_n$  do modelo acima, discuta a propriedade da distribuição a posteriori.**

- Com  $X_i \sim \text{Uniforme}(0, \theta)$ , tem-se que:

$$p(\theta|X_i) \propto p(X_i|\theta)p(\theta)$$

$$p(\theta|X_i) \propto \prod_{i=1}^n \frac{1}{\theta} \cdot \frac{1}{\theta}$$

$$p(\theta|X_i) \propto \frac{1}{\theta^n} \cdot \frac{1}{\theta}$$

$$p(\theta|X_i) \propto \theta^{-(n+1)}$$

- Considerando a condição de que  $\theta \geq \max(X_1, \dots, X_n)$ , tem-se que:

$$p(\theta|X_i) \propto \theta^{-(n+1)}, \text{ se } \theta \geq \max(X_1, \dots, X_n)$$

- Integrando sobre o intervalo de  $\theta$ , tem-se:

$$\int_{\max(X_1, \dots, X_n)}^{\infty} \theta^{-(n+1)} d\theta = -\frac{1}{n\theta^n} \Big|_{\max(X_1, \dots, X_n)}^{\infty}$$

$$\int_{\max(X_1, \dots, X_n)}^{\infty} \theta^{-(n+1)} d\theta = \frac{1}{n(\max(X_1, \dots, X_n))^n}$$

- Encontrando a constante de normalização:

$$c = \frac{n(\max(X_1, \dots, X_n))^n}{\theta^{n+1}}$$

- Assim, a distribuição a posteriori é dada por:

$$p(\theta|X_i) = \frac{n(\max(X_1, \dots, X_n))^n}{\theta^{n+1}}$$

- Nota-se que a distribuição a posteriori se assemelha a uma distribuição Pareto, logo:

$$\theta|X_i \sim \text{Pareto}(n, \max(X_1, \dots, X_n))$$

**(c) Na situação da parte (b), ache:**

**(i) os estimadores bayesianos sob Perda Quadrática e sob Perda Absoluta;**

- O estimador bayesiano de  $\theta$  sob perda quadrática é dado por:



$$\hat{\theta}_q = E[\theta|x] = \int \theta p(\theta|x) d\theta$$

$$\hat{\theta}_q = E[\theta|x] = \int \theta \frac{n(\max(X_1, \dots, X_n))^n}{\theta^{n+1}} d\theta$$

$$\hat{\theta}_q = E[\theta|x] = \frac{n(\max(X_1, \dots, X_n))^n}{n-1}, \text{ com } n > 1.$$

- O estimador bayesiano de  $\theta$  sob perda absoluta é dado por:

$$\hat{\theta}_a = \text{mediana}(\theta|x)$$

$$\hat{\theta}_a = \max(X_1, \dots, X_n) \cdot 2^{1/n}$$

**(ii) O intervalo HPD para  $\theta$  com credibilidade  $100(1 - \alpha)\%$**

- O intervalo HPD é dado pelos limites  $a$  e  $b$  tais que:

$$P(\theta_a < \theta < \theta_b | X_1, \dots, X_n) = 1 - \alpha$$

- Considerando que a distribuição a posteriori de  $\theta$  é dada por  $\theta|x \sim \text{Pareto}(n, \max(X_1, \dots, X_n))$ , tem-se que:

$$F(\theta_a) - F(\theta_b) = 1 - \alpha$$

- Sabe-se que:

$$F(\theta) = 1 - \left( \frac{\max(X_1, \dots, X_n)}{\theta} \right)^n$$

- Assim, o intervalo HPD para  $\theta$  com credibilidade  $100(1 - \alpha)\%$  é dado por:

$$\theta_a = \max(X_1, \dots, X_n)$$

$$\theta_b = \max(X_1, \dots, X_n) \cdot \alpha^{-\left(\frac{1}{n+1}\right)}$$

- Ou seja, o intervalo HPD para  $\theta$  com credibilidade  $100(1 - \alpha)\%$  é dado por:

$$HPD = [\max(X_1, \dots, X_n), \max(X_1, \dots, X_n) \cdot \alpha^{-\left(\frac{1}{n+1}\right)}]$$

**(iii) A probabilidade a posteriori do evento  $\theta > \theta_0$ .**

- Tem-se que a probabilidade de  $\theta > \theta_0$  é dada pela complementar à função de distribuição acumulada em  $\theta_0$ :

$$P(\theta > \theta_0 | X_1, \dots, X_n) = 1 - F(\theta_0)$$

$$P(\theta > \theta_0 | X_1, \dots, X_n) = 1 - \left[ 1 - \left( \frac{\max(X_1, \dots, X_n)}{\theta_0} \right)^n \right]$$

$$P(\theta > \theta_0 | X_1, \dots, X_n) = \left( \frac{\max(X_1, \dots, X_n)}{\theta_0} \right)^n, \text{ se } \theta_0 > \max(X_1, \dots, X_n)$$

### Questão 3

Considere o modelo  $x_1, \dots, x_n | \theta \sim \text{Ber}(\theta)$ .

(a) Calcule a priori de Jeffreys e mostre que ela é própria.

- A priori de Jeffreys é dada por:

$$p(\theta) \propto \sqrt{I(\theta)}$$

$$I(\theta) = -E \left[ \frac{\partial^2}{\partial \theta^2} \log f(x|\theta) \right]$$

$$I(\theta) = -E \left[ \frac{\partial^2}{\partial \theta^2} \log \theta^x (1-\theta)^{1-x} \right]$$

$$I(\theta) = -E \left[ \frac{\partial^2}{\partial \theta^2} (x \log \theta + (1-x) \log(1-\theta)) \right]$$

$$I(\theta) = -E \left[ \frac{\partial}{\partial \theta} \left( \frac{x}{\theta} - \frac{1-x}{1-\theta} \right) \right]$$

$$I(\theta) = -E \left[ \frac{-x}{\theta^2} + \frac{1-x}{(1-\theta)^2} \right]$$

$$I(\theta) = E \left[ \frac{x}{\theta^2} + \frac{1-x}{(1-\theta)^2} \right]$$

$$I(\theta) = \frac{1}{\theta^2} E[x] + \frac{1}{(1-\theta)^2} E[1-x]$$

$$I(\theta) = \frac{1}{\theta^2} \theta + \frac{1}{(1-\theta)^2} (1-\theta)$$

$$I(\theta) = \frac{1}{\theta} + \frac{1}{1-\theta}$$

- Assim, a priori de Jeffreys é dada por:

$$p(\theta) \propto \sqrt{\frac{1}{\theta} + \frac{1}{1-\theta}}$$

- Para mostrar que a priori de Jeffreys é própria, é necessário verificar se a integral da priori é finita:

$$\int \sqrt{\frac{1}{\theta} + \frac{1}{1-\theta}} d\theta$$

```
integrate(function(theta) sqrt(1/theta + 1/(1-theta)), lower = 0, upper = 1)$value
```

[1] 3.141593

- Assim, como a integral é finita, a priori de Jeffreys é própria.

(b) Considere uma amostra aleatória  $X_1, \dots, X_n$  do modelo acima e a priori de Jeffreys. Ache o estimador bayesiano de  $\theta$  sob Perda Quadrática e explique como achar um intervalo HPD para  $\theta$  com credibilidade  $100(1-\alpha)\%$ .

- O estimador bayesiano de  $\theta$  sob perda quadrática é dado por:

$$\hat{\theta} = E[\theta|x] = \int \theta p(\theta|x) d\theta$$

- Um exemplo de cálculo do intervalo HPD para  $\theta$  com credibilidade  $100(1 - \alpha)\%$  pode ser dado por:

```
qbeta(alpha/2, sum(x), n - sum(x))
```

```
qbeta(1-alpha/2, sum(x), n - sum(x))
```

## Lista 4

### Questão 1

Considere uma amostra  $y_1, \dots, y_n$  da distribuição Normal com média  $\mu$  e variância  $\sigma^2 = 1/\tau$  desconhecidas, e suponha que a priori a distribuição de  $(\mu, \tau)$  é especificada da seguinte forma:  $\mu|\tau \sim N(\mu_0, 1/\lambda_0\tau)$  e  $\tau \sim \text{Gama}(\alpha_0, \beta_0)$ , onde  $\lambda_0$ ,  $\alpha_0$  e  $\beta_0$  são positivas.

(a) Ache a distribuição a posteriori de  $p(\mu, \tau|D)$  e as distribuições marginais  $p(\mu|D)$  e  $p(\tau|D)$ .

- A distribuição a posteriori de  $p(\mu, \tau|D)$  é dada por:

$$p(\mu, \tau|D) \propto p(D|\mu, \tau)p(\mu|\tau)p(\tau)$$

$$p(\mu, \tau|D) \propto \prod_{i=1}^n \frac{1}{\sqrt{2\pi\tau}} e^{-\frac{1}{2\tau}(y_i - \mu)^2} \cdot \frac{1}{\sqrt{2\pi\lambda_0\tau}} e^{-\frac{1}{2\lambda_0\tau}(\mu - \mu_0)^2} \cdot \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \tau^{\alpha_0-1} e^{-\beta_0\tau}$$

$$p(\mu, \tau|D) \propto \frac{1}{\sqrt{2\pi\tau}^n} e^{-\frac{1}{2\tau} \sum_{i=1}^n (y_i - \mu)^2} \cdot \frac{1}{\sqrt{2\pi\lambda_0\tau}} e^{-\frac{1}{2\lambda_0\tau}(\mu - \mu_0)^2} \cdot \frac{\beta_0^{\alpha_0}}{\Gamma(\alpha_0)} \tau^{\alpha_0-1} e^{-\beta_0\tau}$$

$$p(\mu, \tau|D) \propto \tau^{n/2-1} e^{-\frac{1}{2\tau} \sum_{i=1}^n (y_i - \mu)^2} \cdot \tau^{1/2} e^{-\frac{1}{2\lambda_0\tau}(\mu - \mu_0)^2} \cdot \tau^{\alpha_0-1} e^{-\beta_0\tau}$$

$$p(\mu, \tau|D) \propto \tau^{n/2+1/2+\alpha_0-1} e^{-\frac{1}{2\tau} \sum_{i=1}^n (y_i - \mu)^2 - \frac{1}{2\lambda_0\tau}(\mu - \mu_0)^2 - \beta_0\tau}$$

$$p(\mu, \tau|D) \propto \tau^{n/2+1/2+\alpha_0-1} e^{-\frac{1}{2\tau}(\sum_{i=1}^n (y_i - \mu)^2 + \frac{1}{\lambda_0}(\mu - \mu_0)^2 + 2\beta_0)}$$

- Assim, a distribuição a posteriori de  $p(\mu, \tau|D)$  é dada por:

$$p(\mu, \tau|D) \sim \text{Gama}(\alpha_0 + n/2, \frac{1}{2}(\sum_{i=1}^n y_i^2 + \frac{1}{\lambda_0}(\mu - \mu_0)^2 + 2\beta_0))$$

(b) Discuta neste contexto o uso da distribuição a priori não informativa  $p(\mu, \tau) \propto 1/\tau$ . A distribuição a posteriori é própria? Qual é a relação da distribuição  $p(\mu|D)$  e os resultados clássicos?

- A priori não informativa  $p(\mu, \tau) \propto 1/\tau$  é uma distribuição imprópria, de forma que a distribuição a posteriori é própria. A distribuição a posteriori de  $\mu$  é dada por:

$$p(\mu|D) = \int p(\mu, \tau|D) d\tau$$

- A distribuição a posteriori de  $\mu$  é dada por:

$$p(\mu|D) \sim t_{2\alpha_0+n}(\mu_0, \frac{1}{\lambda_0(\alpha_0+n)})$$

## Questão 2

Seja  $n = (n_1, \dots, n_k)$  um vetor aleatório com distribuição multinomial e densidade  $p(n|\theta) \propto \prod_{i=1}^k \theta_i^{n_i}$ , onde  $\theta = (\theta_1, \dots, \theta_k)$ ,  $\theta_i > 0$  e  $\sum_i \theta_i = 1$ . Considere a priori para  $\theta$  uma distribuição de Dirichlet com parâmetro  $\alpha = (\alpha_1, \dots, \alpha_k)$ , isto é  $p(\theta) \propto \prod_{i=1}^k \theta_i^{\alpha_i-1}$ .

(c) No caso particular  $\alpha = (0, 0, \dots, 0)$  a distribuição a priori de  $\theta$  é imprópria. Mostre que a distribuição a posteriori é própria se e somente se  $n_i > 0$  para  $i = 1, 2, \dots, k$ .

- A densidade a posteriori é dada por:

$$p(\theta|n) \propto p(n|\theta)p(\theta)$$

$$p(\theta|n) \propto \prod_{i=1}^k \theta_i^{n_i} \cdot \prod_{i=1}^k \theta_i^{-1}$$

$$p(\theta|n) \propto \prod_{i=1}^k \theta_i^{n_i-1}$$

- Sabe-se que para que uma distribuição Dirichlet com parâmetros  $n_i - 1$  (os expoentes na posteriori) seja própria todos os parâmetros devem ser maiores que zero. Para a posteriori integrar para 1 sobre o simplex  $\{\theta \in \mathbb{R}^k : \sum_{i=1}^k \theta_i = 1, \theta_i > 0\}$ , é necessário que todos os expoentes sejam positivos. Portanto, a posteriori será própria se:

$$\begin{cases} n_i - 1 > 0, & \text{para todo } i = 1, 2, \dots, k \\ n_i > 1, & \text{para todo } i = 1, 2, \dots, k \end{cases}$$

### Questão 3

Na véspera do primeiro turno para a eleição de governador do DF em 2010, a Datafolha divulgou uma pesquisa indicando que, de 891 eleitores entrevistados que já tinham decidido em quem votar, Agnelo Queiroz tinha a preferência de 467, Weslian Roriz de 315 e outros candidatos de 109 eleitores. Formule um modelo para analisar esses dados. O interesse centra fundamentalmente em três perguntas:

#### (a) a eleição poderia ser definida no primeiro turno?

- Podemos iniciar a análise entendendo que:

$n = (n_1, n_2, n_3) \sim \text{Multinomial}(891, \theta)$ , onde  $n_1 = 467$ ,  $n_2 = 315$  e  $n_3 = 109$ ;  $\theta = (\theta_1, \theta_2, \theta_3)$  e  $\sum_{i=1}^3 \theta_i = 1$ .

- A distribuição a priori pode ser dada por:

$\theta \sim \text{Dirichlet}(\alpha)$ , onde  $\alpha = (\alpha_1, \alpha_2, \alpha_3)$ .

- Para garantir que seja uma priori não informativa, podemos considerar  $\alpha = (1, 1, 1)$ . Assim, a distribuição a posteriori de  $\theta$  é dada por:

$\theta|n \sim \text{Dirichlet}(n + \alpha)$

$\theta|n \sim \text{Dirichlet}(467 + 1, 315 + 1, 109 + 1)$

$\theta|n \sim \text{Dirichlet}(468, 316, 110)$

- Agora, sabe-se que eleição poderia ser definida no primeiro turno se o candidato Agnelo tivesse mais de 50% dos votos válidos. Portanto, devemos calcular  $P(\theta > 0.5|n)$ .

```
pacman::p_load(gtools)

amostras <- rdirichlet(10000, c(468, 316, 110))
mean(amostras[, 1] > 0.5)
```

```
[1] 0.921
```

#### (b) O candidato Agnelo poderia ser eleito no primeiro turno?

- Assim, a probabilidade de Agnelo ser eleito no primeiro turno é dada por:

$$P(\theta > 0.5) = 1 - \Phi\left(\frac{\log\left[\frac{0.5}{1-0.5}\right] - 0.75}{\sqrt{1+782}}\right)$$

$$P(\theta > 0.5) = 1 - \Phi\left(\frac{\log\left[\frac{1}{2}\right] - 0.75}{\sqrt{783}}\right)$$

$$P(\theta > 0.5) = 1 - \Phi\left(\frac{-0.6931 - 0.75}{\sqrt{783}}\right)$$

$$P(\theta > 0.5) = 1 - \Phi\left(\frac{-1.4431}{\sqrt{783}}\right)$$

$$P(\theta > 0.5) = 1 - \Phi(-0.0516)$$

$$P(\theta > 0.5) = 1 - 0.4794$$

$$P(\theta > 0.5) = 0.5206$$

**(c) qual será a diferença na porcentagem dos votos válidos entre os dois primeiros colocados?**

- A diferença na porcentagem dos votos válidos entre os dois primeiros colocados é dada por:

$$P(\theta_1 - \theta_2 > 0) = 1 - \Phi\left(\frac{\log\left[\frac{467}{782}1 - \frac{467}{782}\right] - 0.75}{\sqrt{1+782}}\right)$$

- Calculando, o resultado é:

$$P(\theta_1 - \theta_2 > 0) = 1 - \Phi\left(\frac{\log\left[\frac{467}{782}1 - \frac{467}{782}\right] - 0.75}{\sqrt{1+782}}\right)$$

## Lista 5

### Questão 2

Considere  $n = 12$  ensaios de Bernoulli com probabilidade de sucesso  $p$  e  $y = 9$  sucessos. Suponha que a distribuição a priori de  $p$  é especificada de forma que  $\eta = \log\left[\frac{p}{1-p}\right]$  segue uma distribuição Normal com média  $\mu = 0$  e variância  $\sigma^2 = 1$ . Obtenha aproximações para  $\mathbb{E}(p|y = 9)$ ,  $\text{DP}(p|y = 9)$  e  $\Pr(p > \frac{1}{2}|y = 9)$ . Repita o exercício para os casos que  $\sigma^2 = 4$  e  $9$  e compare com o caso  $\sigma^2 = 1$ .

- A distribuição a priori de  $\eta$  é dada por:

$$p(\eta) = \frac{1}{\sqrt{2\pi}} e^{-\frac{\eta^2}{2}}$$

- Assim, a distribuição a posteriori de  $\eta$  é dada por:

$$p(\eta|y) \propto p(y|\eta)p(\eta)$$

$$p(\eta|y) \propto \binom{12}{9} e^{9\eta} (1 - e^\eta)^3 e^{-\frac{\eta^2}{2}}$$

- A distribuição a posteriori de  $\eta$  é dada por:

$$p(\eta|y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(\eta-0.75)^2}{2(1+12)}}$$

- Assim, a distribuição a posteriori de  $p$  é dada por:

$$p(p|y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(\log[\frac{p}{1-p}]-0.75)^2}{2(1+12)}}$$

- A esperança a posteriori de  $p$  é dada por:

$$\mathbb{E}(p|y) = \frac{1}{1+e^{-0.75}}$$

- A variância a posteriori de  $p$  é dada por:

$$\text{Var}(p|y) = \frac{1}{(1+e^{-0.75})^2} \cdot \frac{e^{-0.75}}{(1+e^{-0.75})^2}$$

- A probabilidade a posteriori de  $p > \frac{1}{2}$  é dada por:

$$\Pr(p > \frac{1}{2}|y) = 1 - \Phi\left(\frac{\log[\frac{1}{2}1-\frac{1}{2}]-0.75}{\sqrt{1+12}}\right)$$

- Assim, para  $\sigma^2 = 4$ :

$$p(p|y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(\log[\frac{p}{1-p}]-0.75)^2}{2(4+12)}}$$

$$\mathbb{E}(p|y) = \frac{1}{1+e^{-0.75}}$$

$$\text{Var}(p|y) = \frac{1}{(1+e^{-0.75})^2} \cdot \frac{e^{-0.75}}{(4+12)^2}$$

$$\Pr(p > \frac{1}{2}|y) = 1 - \Phi\left(\frac{\log[\frac{1}{2}1-\frac{1}{2}]-0.75}{\sqrt{4+12}}\right)$$

- E, para  $\sigma^2 = 9$ :

$$p(p|y) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(\log[\frac{p}{1-p}]-0.75)^2}{2(9+12)}}$$

$$\mathbb{E}(p|y) = \frac{1}{1+e^{-0.75}}$$

$$\text{Var}(p|y) = \frac{1}{(1+e^{-0.75})^2} \cdot \frac{e^{-0.75}}{(9+12)^2}$$

$$\Pr(p > \frac{1}{2}|y) = 1 - \Phi\left(\frac{\log[\frac{1}{2}1-\frac{1}{2}]-0.75}{\sqrt{9+12}}\right)$$