

# LISTA 3

## ESTATÍSTICA COMPUTACIONAL

Tailine J. S. Nonato

2023-11-30

### Dados

```
climbing <- read_csv("climbing_statistics.csv")
weather <- read_csv("Rainier_Weather.csv")
convert <- function(x) (x-32) * 5/9
shift <- function(x) x - mean(x)

dados <- inner_join(climbing, weather) %>%
  select(-matches("Percent|Battery")) %>%
  filter(Attempted >= Succeeded, Route != "glacier only - no summit attempt", Route != "U
  mutate(`Temperature AVG` = convert(`Temperature AVG`), Cleaver = Route=="Disappointment
  select(Date, Succeeded, everything()) %>%
  rename(Data = Date,
         Rota = Route,
         Sucessos = Succeeded,
         Tentativas = Attempted,
         Temperatura = `Temperature AVG`,
         Umidade_relativa = `Relative Humidity AVG`,
         Velocidade_vento = `Wind Speed Daily AVG`,
         Direc_vento = `Wind Direction AVG`,
         Radiacao_solar = `Solare Radiation AVG`) %>%
  group_by(Data, Rota) %>%
  mutate(Sucessos = sum(Sucessos), Tentativas = sum(Tentativas)) %>%
  distinct()
kable(head(dados), align='l')
```

Data	Sucesso	Rota	Tentativa	Temperatura	Umidade	Velocidade	Altitude	Dieta	Radiao	Cleaver
2015-11-27	0	Disappointment Cleaver	1	-	19.71500	27.839583	68.0041788	49625	TRUE	
2015-11-21	0	Disappointment Cleaver	1	-	21.69071	2.245833	117.549673	66042	TRUE	
2015-10-15	0	Disappointment Cleaver	1	8.026620	17.21125	17.163625	259.12138	38700	TRUE	
2015-10-13	0	Little Tahoma	8	4.988657	18.33571	19.591167	279.77917	76.38267	FALSE	
2015-10-09	0	Disappointment Cleaver	1	3.478009	14.32917	65.138333	264.68750	7.79129	TRUE	
2015-10-03	0	Disappointment Cleaver	12	-	62.33708	13.125042	153.93167	96.37521	TRUE	

## Item A

Conduza um teste de hipóteses por simulação para avaliar a hipótese nula de que a média do número de sucessos obtidos pela rota ‘Disappointment Cleaver’ é igual a média das demais rotas (conjuntamente).

- Respostas

Tem-se como hipóteses:

$$\begin{cases} H_0 : \mu_1 = \mu_{2,\dots,n} \\ H_1 : \mu_1 \neq \mu_{2,\dots,n} \end{cases}$$

Observando primeiramente de forma ‘exploratória’, calculamos as médias e a diferenças entre elas.

```
tab1<- tidy(summary(dados$Sucessos))
kable(tab1,align='l')
```

Table 2: Sumário de Sucessos

minimum	q1	median	mean	q3	maximum
0	0	2	10.40343	17	92

```

tab2 <- dados %>% filter(Rota == 'Disappointment Cleaver')
mu1 <- mean(tab2$Sucessos)

tab3 <- dados %>% filter(Rota != 'Disappointment Cleaver')
mu2 <- mean(tab3$Sucessos)
diff <- mu1-mu2

tab4 <- data.frame(mu1,mu2,diff)
kable(tab4,align='l')

```

Table 3: Análitica das Médias

mu1	mu2	diff
20.48876	4.170139	16.31863

Considerando o S mario de Sucesso, observa-se uma m dia de em torno de 10.4 sucessos em todas as rotas avaliadas, assim o valor da diferen a 16.32 pode ser considerado alto, indicando a poss vel diferen a de m dias.

Realizando uma simula  o com  $n = 10.000$ , tem-se que:

```

otherR <- dados %>%
  filter(Rota != 'Disappointment Cleaver') %>%
  select(Sucessos)
DCR <- dados %>%
  filter(Rota == 'Disappointment Cleaver') %>%
  select(Sucessos)

n <- 10000
diff2 <- numeric(n)
for (i in 1:n){
  mu11 <- sample(DCR$Sucessos,size=10,replace=T)
  mu22 <- sample(otherR$Sucessos,size=10,replace=T)
  mu11 <- mean(mu11)
  mu22 <- mean(mu22)
  diff2[i] <- abs(mu11 - mu22)
}

kable(tidy(summary(diff2)),align='l')

```

Table 4: Sumário de Diferenças na Simulação

minimum	q1	median	mean	q3	maximum
0	11.5	16.1	16.32942	20.9	45.2

```
prob <- data.frame(paste0(round(mean(diff2)/n*100,2), '%'))
colnames(prob) <- c("Probabilidade")
kable(prob, align='c')
```

Table 5:  $P(H_0 \text{ é aceita} \mid H_0 \text{ é verdadeira})$ 

Probabilidade
0.16%

Com uma probabilidade  $\sim 0.01$  de que as médias seriam iguais, há evidências para rejeitar  $H_0$ .

## Item B

Obtenha o estimador de máxima verossimilhança de  $\alpha$  e  $\beta$  considerando o modelo proposto.

Dica: Use a função `optim` do R para achar o ponto que maximiza a log-verossimilhança.

### • Respostas

```
lv <- function(p,temp,sucesso){
  l <- exp(p[1]+p[2]*temp)
  sum(dpois(sucesso,l,log=T))}
estim <- optim(c(0,0), function(.) -lv(.,temp=dados$Temperatura, sucesso=dados$Sucessos))$

estim<- data.frame(t(estim))
colnames(estim) <- c('Alpha','Beta')
kable(estim, align='c')
```

Table 6: Estimadores de Máxima Verossimilhança

Alpha	Beta
1.988505	0.0812769

## Item C

Estime a distribuição de probabilidade do número de sucessos previstos para um dia em que a temperatura seja de 15 graus.

- **Respostas**

Para verificar, basta utilizar a mesma estrutura anterior, mas considerando o valor fixo  $T_i = 15$ .

```
estim2 <- optim(c(0,0), function(.) -lv(.,temp=15, sucesso=dados$Sucessos))$`par`  
estim2 <- data.frame(t(estim2))  
  
colnames(estim2) <- c('Alpha', 'Beta')  
kable(estim2, align='c')
```

Table 7: Estimadores de Máxima Verossimilhança

Alpha	Beta
0.137087	0.1470131

Verificando um intervalo [0,95] (min-max sucessos), tem-se que:

```
x <- 0:95  
pr <- (estim2[1]+estim2[2])*15  
lambda<- as.numeric(exp(pr))  
fprob <- dpois(x, lambda)  
  
plot(fprob)
```




Figure 1: Distribuição de Probabilidade de Sucessos quando Temperatura é 15° C

## Item D

Construa um intervalo de confiança de 95% para  $\exp(\beta)$  a partir do método de bootstrap paramétrico. Interprete o resultado considerando o contexto dos dados.

Dica: calcule o aumento percentual da média esperada quando a temperatura aumenta em 1 grau Celsius.

### • Respostas

```
sucessos <- numeric()
beta.estim <- numeric()
SE <- numeric()

for(j in 1:1000){
  for(i in 1:nrow(dados)){
    pr <- exp(as.numeric(estim[1]+estim[2]*dados$Temperatura[i]))
    sucessos[i] <- rpois(1,pr)}
  estim3 <- optim(c(0,0), function(.) -lv(., temp=dados$Temperatura, sucesso=sucessos))$
```

```

beta.estim[j] <- estim3[2]

SE[j] <- mean((sucessos-exp(as.numeric(estim[1])+as.numeric(estim[2])*dados$Temperatur
sucessos <- numeric()
}
y <- exp(beta.estim)
kable(tidy(summary(y)))

```

Table 8: Sumário de  $Y \sim \exp(\beta)$

minimum	q1	median	mean	q3	maximum
1.075012	1.082565	1.084684	1.084686	1.086665	1.094451

```
plot(y)
```




Figure 2: Distribuição de Probabilidade de  $Y \sim \exp(\beta)$

```

alpha <- 1-0.95
inf<-as.numeric(quantile(y, probs= (alpha/2)))
sup<-as.numeric(quantile(y, probs= (1-alpha/2)))

```

```
ic<- data.frame(inf,sup)
colnames(ic) <-c('Limite Inferior','Limite Superior')
kable(ic,align='c')
```

Limite Inferior	Limite Superior
1.078998	1.090514

$$IC(\exp(\beta), 95\%) = [1.078, 1.091]$$

## Item E

Faça um diagnóstico do modelo via simulação. Para tanto, gere dados sintéticos usando o modelo obtido no item b, ajuste um novo modelo sobre os dados sintéticos e calcule o Erro quadrático médio (MSE). Repita esse procedimento 10000 vezes e compare os MSEs gerados com aquele do modelo obtido em b. Comente os resultados.

- **Respostas**

Com fins de otimização, a simulação foi realizada no Item D, mas apenas com 1000 repetições por limitações de hardware e tempo de execução.

```
MSE <- mean(SE)
kable(MSE,align='c')
```

Table 10: Erro Quadrático Médio

x
0.0215966