

# LISTA 3

## ANÁLISE DE SÉRIES TEMPORAIS

Tailine J. S. Nonato

2024-04-10

### Descrição da atividade

Exercícios 4.1, 4.5, 4.15, 4.18 e 4.24 do Cap.4 (pp. 81-83) de Cryer & Chan (2008)

### Exercício 4.1

Use first principles to find the autocorrelation function for the stationary process defined by  $Y_i = 5 + e_i - \frac{1}{2} \cdot e_{i-1} + \frac{1}{4} \cdot e_{i-2}$ .

### Respostas

A autocorrelação é dada por  $\rho_k = \frac{Cov(Y_t, Y_{t-k})}{Var(Y_t)}$ . Logo, temos que:

i. Calculando  $Cov(Y_t, Y_{t-k}) = \gamma_k$ :

$$\gamma_k = Cov(5 + e_t - \frac{1}{2} \cdot e_{t-1} + \frac{1}{4} \cdot e_{t-2}, 5 + e_{t-k} - \frac{1}{2} \cdot e_{t-k-1} + \frac{1}{4} \cdot e_{t-k-2})$$

$$\gamma_k = Cov(e_t, e_{t-k}) - \frac{1}{2} \cdot Cov(e_{t-1}, e_{t-k}) + \frac{1}{4} \cdot Cov(e_{t-2}, e_{t-k})$$

- Se  $k = 1$ , então:

$$\gamma_1 = -\frac{1}{2} \cdot Var(e_{t-1}) - \frac{1}{8} \cdot Var(e_{t-2}) = -\frac{5}{8}\sigma^2$$

- Se  $k = 2$ , então:

$$\gamma_2 = -\frac{1}{4} \cdot Var(e_{t-2}) = -\frac{1}{4}\sigma^2$$

- Se  $k > 2$ , então:

$$Cov(Y_t, Y_{t-k}) = 0$$

ii. Calculando  $Var(Y_t) = \gamma_0$ :

$$\gamma_0 = Var(5 + e_t - \frac{1}{2}e_{t-1} + \frac{1}{4}e_{t-2})$$

$$\gamma_0 = Var(e_t) + \frac{1}{4}Var(e_{t-1}) + \frac{1}{16}Var(e_{t-2})$$

$$\gamma_0 = \sigma^2 + \frac{1}{4}\sigma^2 + \frac{1}{16}\sigma^2$$

$$\gamma_0 = \frac{21}{16}\sigma^2$$

iii. Assim, a autocovariancia é dada por:

$$\gamma_k = \begin{cases} \frac{21}{16}\sigma^2, & \text{se } k = 0 \\ -\frac{5}{8}\sigma^2, & \text{se } k = 1 \\ -\frac{1}{4}\sigma^2, & \text{se } k = 2 \\ 0, & \text{se } k > 2 \end{cases}$$

iv. Agora, calculando a autocorrelação tem-se que:

$$\rho_k = \frac{\gamma_k}{\gamma_0}$$

$$\rho_k = \begin{cases} 1, & \text{se } k = 0 \\ -\frac{10}{21}, & \text{se } k = 1 \\ -\frac{4}{21}, & \text{se } k = 2 \\ 0, & \text{se } k > 2 \end{cases}$$

### Exercício 4.5

Calculate and sketch the autocorrelation functions for each of the following  $AR(1)$  models. Plot for sufficient lags that the autocorrelation function has nearly died out.

- a.  $\phi_1 = 0.6$
- b.  $\phi_1 = -0.6$
- c.  $\phi_1 = 0.95$  (Do out to 20 lags.)
- d.  $\phi_1 = 0.3$

## Respostas

A autocorrelação é dada por  $\rho_k = \phi^k$ . Para criar o gráfico, foi criada a função `ex45` que recebe o valor de  $\phi$  e plota a autocorrelação para 20 lags. Antes de plotar, é necessário definir a função `rho` que calcula a autocorrelação para um determinado lag  $k$ .

Na função `ex45`, é criado um vetor `k` com os lags de 0 a 20 e, em seguida, é calculado a autocorrelação para cada lag utilizando a função `sapply`. Por fim, é plotado o gráfico da autocorrelação para os lags de 0 a 20.


```
rho <- function(phi, k){  
  if(k == 0){return(1)}  
  else {return(phi^k)}  
}  
  
ex45 <- function(phi){  
  k <- seq(0, 20, 1)  
  y <- sapply(k, function(x) rho(phi, x))  
  plot(k, y, type = "h",  
        xlab = "Lags",  
        ylab = "Autocorrelação",  
        main = paste("Autocorrelação para phi = ",  
                      phi)))}
```

i. Para  $\phi_1 = 0.6$ :

$$\rho_k = \begin{cases} 1, & \text{se } k = 0 \\ 0.6^k, & \text{se } k > 0 \end{cases}$$

```
ex45(0.6)
```

### Autocorrelação para phi = 0.6




ii. Para  $\phi_1 = -0.6$ :

$$\rho_k = \begin{cases} 1, & \text{se } k = 0 \\ (-0.6)^k, & \text{se } k > 0 \end{cases}$$

`ex45(-0.6)`

### Autocorrelação para phi = -0.6




iii. Para  $\phi_1 = 0.95$ :

$$\rho_k = \begin{cases} 1, & \text{se } k = 0 \\ 0.95^k, & \text{se } k > 0 \end{cases}$$

`ex45(0.95)`

### Autocorrelação para phi = 0.95




iv. Para  $\phi_1 = 0.3$ :

$$\rho_k = \begin{cases} 1, & \text{se } k = 0 \\ 0.3^k, & \text{se } k > 0 \end{cases}$$

`ex45(0.3)`

### Autocorrelação para phi = 0.3



#### Exercício 4.15

Consider the  $AR(1)$  model  $Y_t = \phi Y_{t-1} + e_t$ . Show that if  $|\phi| = 1$  the process cannot be stationary. (Hint: Take variances of both sides.)

#### Respostas

Se  $|\phi| = 1$ , então a equação do modelo  $AR(1)$  se torna  $Y_t = Y_{t-1} + e_t$ . Para verificar se o processo é estacionário, é necessário verificar se a média e a variância são constantes ao longo do tempo.

- i. Calculando a média:

$$E(Y_t) = E(Y_{t-1} + e_t) = E(Y_{t-1}) + E(e_t)$$

$$E(Y_t) = E(Y_{t-1})$$

$$E(Y_t) = E(Y_{t-2})$$

...

$$E(Y_t) = E(Y_{t-k})$$

- ii. Calculando a variância:

$$\text{Var}(Y_t) = \text{Var}(Y_{t-1} + e_t)$$

$$\text{Var}(Y_t) = \text{Var}(Y_{t-1}) + \text{Var}(e_t)$$

$$\text{Var}(Y_t) = \text{Var}(Y_{t-1}) + \sigma^2$$

$$\text{Var}(Y_t) = \text{Var}(Y_{t-2}) + 2\sigma^2$$

...

$$\text{Var}(Y_t) = \text{Var}(Y_{t-k}) + k\sigma^2$$

Como a média é constante ao longo do tempo, então o processo poderia ser dito estacionário. No entanto, como a variância não é constante ao longo do tempo, então o processo não é estacionário.

Assim, se  $|\phi| = 1$ , o processo não é estacionário, já que a variância causa uma contradição.

### Exercício 4.18

Consider a process that satisfies the zero-mean, “stationary”  $AR(1)$  equation  $Y_t = \phi Y_{t-1} + e_t$  with  $-1 < \phi < 1$ . Let  $c$  be any nonzero constant, and define  $W_t = Y_t + c\phi^t$ .

- Show that  $E(W_t) = c\phi^t$ .
- Show that  $W_t$  satisfies the “stationary”  $AR(1)$  equation  $W_t = \phi W_{t-1} + e_t$ .
- Is  $W_t$  stationary?

### Respostas

#### Item A

Para calcular a média de  $W_t$ , temos que:

$$E(W_t) = E(Y_t + c\phi^t)$$

$$E(W_t) = E(Y_t) + E(c\phi^t)$$

Como  $E(Y_t) = 0$ , então:

$$E(W_t) = 0 + c\phi^t$$

$$E(W_t) = c\phi^t$$



**Item B**

Para verificar se  $W_t$  satisfaz a equação  $AR(1)$ , temos que:

$$\phi W_{t-1} + e_t = \phi(Y_{t-1} + c\phi^{t-1}) + e_t$$

$$\phi W_{t-1} + e_t = \phi Y_{t-1} + c\phi^t + e_t$$

$$\phi W_{t-1} + e_t = Y_t + c\phi^t$$

$$\phi W_{t-1} + e_t = W_t$$

**Item C**

Para verificar se  $W_t$  é estacionário, é necessário verificar se a média e a variância são constantes ao longo do tempo.

i. Calculando a média:

$$E(W_t) = c\phi^t$$

A média depende de  $t$ , logo não é constante ao longo do tempo, então o processo não é estacionário.

ii. Calculando a variância:

$$Var(W_t) = Var(Y_t + c\phi^t)$$

$$Var(W_t) = Var(Y_t) + Var(c\phi^t)$$

$$Var(W_t) = Var(Y_t) + 0$$

$$Var(W_t) = Var(Y_t)$$

Como a variância é constante ao longo do tempo, então o processo poderia ser dito estacionário. No entanto, observou-se que a média depende de  $t$  e essa informação já era suficiente para determinar que o processo não é estacionário.

### Exercício 4.24

Let  $e_t$  be a zero-mean, unit-variance white noise process. Consider a process that begins at time  $t = 0$  and is defined recursively as follows. Let  $Y_0 = c_1 e_0$  and  $Y_1 = c_2 Y_0 + e_1$ . Then let  $Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + e_t$  for  $t > 1$  as in an  $AR(2)$  process.

- Show that the process mean is zero.
- For particular values of  $\phi_1$  and  $\phi_2$  within the stationarity region for an  $AR(2)$  model, show how to choose  $c_1$  and  $c_2$  so that both  $Var(Y_0) = Var(Y_1)$  and the lag 1 autocorrelation between  $Y_1$  and  $Y_0$  match that of a stationary  $AR(2)$  process with parameters  $\phi_1$  and  $\phi_2$ .
- Once the process  $Y_t$  is generated, show how to transform it to a new process that has any desired mean and variance. (This exercise suggests a convenient method for simulating stationary  $AR(2)$  processes.)

### Respostas

#### Item A

Para calcular a média do processo, temos que:

$$E(Y_t) = E(\phi_1 Y_{t-1} + \phi_2 Y_{t-2} + e_t)$$

$$E(Y_t) = \phi_1 E(Y_{t-1}) + \phi_2 E(Y_{t-2}) + E(e_t)$$

$$E(Y_t) = \phi_1 E(Y_{t-1}) + \phi_2 E(Y_{t-2})$$

$$E(Y_t) = \phi_1 \phi_1 E(Y_{t-2}) + \phi_2 E(Y_{t-2})$$

$$E(Y_t) = \phi_1 \phi_1 \phi_1 E(Y_{t-3}) + \phi_2 \phi_1 E(Y_{t-3})$$

...

$$E(Y_t) = \phi_1^t E(Y_0)$$

Como  $E(Y_0) = 0$ , então:

$$E(Y_t) = 0$$

**Item B**

Para escolher  $c_1$  e  $c_2$  de forma que  $Var(Y_0) = Var(Y_1)$  e a autocorrelação entre  $Y_1$  e  $Y_0$  seja a mesma de um processo  $AR(2)$  estacionário, temos que:

- i. Calculando a variância:

$$Var(Y_0) = Var(c_1 e_0)$$

$$Var(Y_0) = c_1^2 Var(e_0)$$

$$Var(Y_0) = c_1^2$$

E

$$Var(Y_1) = Var(c_2 Y_0 + e_1)$$

$$Var(Y_1) = c_2^2 Var(Y_0) + Var(e_1)$$

$$Var(Y_1) = c_2^2 c_1^2 + 1$$

Para que  $Var(Y_0) = Var(Y_1)$ , então:

$$c_1^2 = c_2^2 c_1^2 + 1$$

$$1 = c_2^2 + \frac{1}{c_1^2}$$

$$c_2^2 = 1 - \frac{1}{c_1^2}$$

- ii. Calculando a autocorrelação:

$$\rho_{Y_1, Y_0} = \frac{Cov(Y_1, Y_0)}{\sqrt{Var(Y_1)Var(Y_0)}}$$

$$\rho_{Y_1, Y_0} = \frac{Cov(c_2 Y_0 + e_1, c_1 e_0)}{\sqrt{Var(Y_1)Var(Y_0)}}$$

$$\rho_{Y_1, Y_0} = \frac{c_2 c_1 Var(e_0)}{\sqrt{Var(Y_1)Var(Y_0)}}$$

$$\rho_{Y_1, Y_0} = \frac{c_2 c_1}{\sqrt{Var(Y_1)Var(Y_0)}}$$

$$\rho_{Y_1, Y_0} = \frac{c_2 c_1}{\sqrt{(c_2^2 c_1^2 + 1)c_1^2}}$$

Para que a autocorrelação entre  $Y_1$  e  $Y_0$  seja a mesma de um processo  $AR(2)$  estacionário, então:

$$\rho_{Y_1, Y_0} = \frac{c_2 c_1}{\sqrt{(c_2^2 c_1^2 + 1)c_1^2}} = \frac{\phi_2}{\sqrt{1 + \phi_1^2}}$$

Dessa forma, é possível escolher:

$$c_1 = \sqrt{\frac{1}{1-\phi_2^2}}$$

$$c_2 = \sqrt{1 - \frac{1}{c_1^2}}$$

Cabe verificar se estas constantes satisfazem  $Var(Y_0) = Var(Y_1)$  e  $\rho_{Y_1, Y_0} = \frac{\phi_2}{\sqrt{1+\phi_1^2}}$ .

$$Var(Y_0) = Var(c_1 e_0) = c_1^2 = \frac{1}{1-\phi_2^2} = 1$$

$$Var(Y_1) = Var(c_2 Y_0 + e_1) = c_2^2 Var(Y_0) + 1 = 1$$

$$\rho_{Y_1, Y_0} = \frac{c_2 c_1}{\sqrt{(c_2^2 c_1^2 + 1) c_1^2}} = \frac{\phi_2}{\sqrt{1+\phi_1^2}}$$

### Item C

Para transformar o processo  $Y_t$  em um novo processo com qualquer média e qualquer variância, é possível realizar uma padronização. Assim, o novo processo  $Z_t$  é dado por:

$$Z_t = \frac{Y_t - E(Y_t)}{\sqrt{Var(Y_t)}}$$

Dessa forma, o novo processo  $Z_t$  terá média zero e variância unitária. Para obter um processo com qualquer média e qualquer variância, basta multiplicar o processo  $Z_t$  pela raiz da variância desejada e somar a média desejada:

$$Z_t = \sigma Z_t + \mu$$

Assim, o novo processo  $Z_t$  terá média  $\mu$  e variância  $\sigma^2$ .