

LISTA 6

ANÁLISE DE SÉRIES TEMPORAIS

Tailine J. S. Nonato

July 15, 2024

Descrição da Atividade

Tente analisar separadamente as seguintes séries temporais mensais encontradas no arquivo `ALGONQUIN_PARK_Ontario_Canada.csv`:

1. “Mean Max Temp (°C)”,
2. “Mean Min Temp (°C)”,
3. “Mean Temp (°C)”,
4. “Extr Max Temp (°C)”,
5. “Extr Min Temp (°C)”,
6. “Total Rain (mm)”,
7. “Total Snow (cm)”,
8. “Total Precip (mm)”.

Respostas

Carregando os pacotes necessários

```
if (!require(pacman)) install.packages("pacman")
pacman::p_load(tidyverse, readxl, knitr, aTSA, forecast)
options(OutDec = ",")
```

Leitura e manipulação dos dados

```
df <- read_csv("ALGONQUIN_PARK_Ontario_Canada.csv")
df$date <- as.Date(paste0(df$`Date/Time`, "-01"), format = "%Y-%m-%d")
```

Automatização da análise

Para fins de replicabilidade, cria-se uma função em R para realizar todas as análises acima em diferentes séries temporais.

```
classificar_modelo <- function(mape) {
  if (mape < 10) {
    return("Excelente")
  } else if (mape < 20) {
    return("Bom")
  } else if (mape < 50) {
    return("Razoável")
  } else {
    return("Ruim")
  }
}

calcular_mape <- function(validacao, previsao) {
  n <- length(validacao)
  m <- round(n * 0.8)
  mape <- round(
    (100 / (n - m)) * sum(
      abs((validacao[(m + 1):n] - previsao$mean[(m + 1):n]) / validacao[(m + 1):n])),0)
  return(mape)
}

analise_serie_temporal <- function(serie_temporal) {
  serie_temporal <- na.omit(serie_temporal)
  if (length(serie_temporal) < 50) {
    stop("Série temporal muito curta para análise significativa.")
  }
  if (length(serie_temporal) == 0) {
    stop("Série temporal está vazia após a remoção de NA.")
  }
}
```

```

plot(serie_temporal, type = "l", main = "Série Temporal")
acf(serie_temporal, lag.max = 12, main = "Função de Autocorrelação")
pacf(serie_temporal, lag.max = 12, main = "Função de Autocorrelação Parcial")

teste_adf <- aTSA::adf.test(serie_temporal)
valor_p_adf <- if (!is.null(teste_adf$p.value)) teste_adf$p.value else NA
d <- ifelse(!is.na(valor_p_adf) && valor_p_adf > 0.05, 1, 0)

if (length(d) == 0) {
  stop("d é vazio após o teste ADF.")
}

s <- 12
D <- ifelse(d == 1, 1, 0)

if (d == 1) {
  serie_temporal <- diff(serie_temporal, differences = d)
}

comprimento_st <- length(serie_temporal)
m <- round(comprimento_st * 0.8)
treinamento <- serie_temporal[1:m]
validacao <- serie_temporal[(m + 1):comprimento_st]

valores_p <- 0:2
valores_q <- 0:2
valores_P <- 0:1
valores_Q <- 0:1

resultados <- list()

for (p in valores_p) {
  for (q in valores_q) {
    for (P in valores_P) {
      for (Q in valores_Q) {
        modelo <- tryCatch({
          Arima(treinamento, order = c(p, d, q), seasonal = c(P, D, Q, s))
        }, error = function(e) {
          NULL
        })
      }
    }
  }
}

```

```

        if (!is.null(modelo)) {
          valor_bic <- BIC(modelo)
          resultados[[paste(p, q, P, Q, sep = "_")] <- valor_bic
        }
      }
    }
  }
}

resultados_df <- do.call(rbind, lapply(names(resultados), function(x) {
  partes <- unlist(strsplit(x, "_"))
  data.frame(p = as.numeric(partes[1]), q = as.numeric(partes[2]),
             P = as.numeric(partes[3]), Q = as.numeric(partes[4]),
             BIC = resultados[[x]])
}))

melhor_modelo <- resultados_df[resultados_df$BIC == min(resultados_df$BIC),]
n <- nrow(melhor_modelo)
modelos <- vector("list", n)

for (i in 1:n) {
  p <- melhor_modelo$p[i]
  q <- melhor_modelo$q[i]
  P <- melhor_modelo$P[i]
  Q <- melhor_modelo$Q[i]

  modelos[[i]] <- Arima(treinamento, order = c(p, d, q), seasonal = c(P, D, Q, s))
}

valores_bic <- numeric(n)

for (i in 1:n) {
  valores_bic[i] <- BIC(modelos[[i]])
}

indice_melhor_modelo_bic <- which.min(valores_bic)
modelo_final <- modelos[[indice_melhor_modelo_bic]]

checkresiduals(modelo_final)
previsao <- forecast(modelo_final, h = length(validacao))
plot(previsao)

```

```

lines(validacao, col = 'red')

mape <- calcular_mape(validacao, previsao)
mae <- mean(abs(validacao - previsao$mean))
classificacao <- classificar_modelo(mape)

return(list(
  Modelo = modelo_final,
  MAPE = mape,
  MAE = mae,
  Classificacao = classificacao))
}


```

Análise da série “Mean Max Temp (°C)”


```

analise_serie_temporal(df$`Mean Max Temp (°C)`)


```



Função de Autocorrelação



Função de Autocorrelação Parcial



Augmented Dickey-Fuller Test
alternative: stationary

Type 1: no drift no trend

	lag	ADF	p.value
[1,]	0	-4,94	0,01
[2,]	1	-12,03	0,01
[3,]	2	-13,70	0,01
[4,]	3	-8,66	0,01
[5,]	4	-5,86	0,01
[6,]	5	-3,34	0,01

Type 2: with drift no trend


	lag	ADF	p.value
[1,]	0	-6,61	0,01
[2,]	1	-18,27	0,01
[3,]	2	-28,92	0,01
[4,]	3	-26,80	0,01
[5,]	4	-27,87	0,01
[6,]	5	-22,81	0,01

Type 3: with drift and trend

	lag	ADF	p.value
[1,]	0	-6,61	0,01
[2,]	1	-18,26	0,01
[3,]	2	-28,91	0,01
[4,]	3	-26,78	0,01
[5,]	4	-27,87	0,01
[6,]	5	-22,82	0,01

Note: in fact, p.value = 0.01 means p.value <= 0.01

Residuals from ARIMA(2,0,2) with non-zero mean




Ljung-Box test

data: Residuals from ARIMA(2,0,2) with non-zero mean
Q* = 25,609, df = 6, p-value = 0,0002632

Model df: 4. Total lags used: 10

Forecasts from ARIMA(2,0,2) with non-zero mean



```
$Modelo
Series: treinamento
ARIMA(2,0,2) with non-zero mean

Coefficients:
          ar1      ar2      ma1      ma2      mean
          1,7322 -0,9999 -1,6541  0,9375  9,7432
s.e.    0,0004   0,0001   0,0213  0,0209  0,1157

sigma^2 = 5,002:  log likelihood = -923,45
AIC=1858,9   AICc=1859,11   BIC=1883,06

$MAPE
[1] 49

$MAE
[1] 1,645096


$Classificacao
[1] "Razoável"
```

O teste ADF sugere estacionariedade da série. O modelo selecionado com o critério de BIC mínimo é ARIMA(2,0,2). No entanto, o teste de Ljung-Box rejeita a hipótese nula de normal-


idade dos resíduos. Pela avaliação do MAPE, o modelo seria razoável, mas dada a rejeição da normalidade, o modelo não é adequado.

Análise da série “Mean Min Temp (°C)”


```
analise_serie_temporal(df$`Mean Min Temp (°C)`)
```



Função de Autocorrelação



Função de Autocorrelação Parcial



Augmented Dickey-Fuller Test
alternative: stationary

Type 1: no drift no trend

	lag	ADF	p.value
[1,]	0	-6,79	0,01
[2,]	1	-14,63	0,01
[3,]	2	-22,81	0,01
[4,]	3	-21,36	0,01
[5,]	4	-18,66	0,01
[6,]	5	-13,48	0,01

Type 2: with drift no trend


	lag	ADF	p.value
[1,]	0	-6,96	0,01
[2,]	1	-15,14	0,01
[3,]	2	-24,56	0,01
[4,]	3	-24,92	0,01
[5,]	4	-25,11	0,01
[6,]	5	-21,40	0,01

Type 3: with drift and trend

	lag	ADF	p.value
[1,]	0	-6,97	0,01
[2,]	1	-15,15	0,01
[3,]	2	-24,60	0,01
[4,]	3	-25,04	0,01
[5,]	4	-25,40	0,01
[6,]	5	-21,84	0,01

Note: in fact, p.value = 0.01 means p.value <= 0.01

Residuals from ARIMA(2,0,2) with non-zero mean




Ljung-Box test

```
data: Residuals from ARIMA(2,0,2) with non-zero mean
Q* = 51,301, df = 6, p-value = 2,576e-09
```

```
Model df: 4.    Total lags used: 10
```

Forecasts from ARIMA(2,0,2) with non-zero mean



```
$Modelo
Series: treinamento
ARIMA(2,0,2) with non-zero mean

Coefficients:
          ar1      ar2      ma1      ma2      mean
          1,7321 -0,9999 -1,6837  0,9568 -2,5035
s.e.      0,0003  0,0001  0,0201  0,0152  0,1319

sigma^2 = 7,001:  log likelihood = -992,95
AIC=1997,89  AICc=1998,1  BIC=2022,05

$MAPE
[1] 34

$MAE
[1] 2,100566


$Classificacao
[1] "Razoável"
```

O teste ADF sugere estacionariedade da série. O modelo selecionado com o critério de BIC mínimo é ARIMA(2,0,2). O teste de Ljung-Box rejeita a hipótese nula de normalidade dos


resíduos. Pela avaliação do MAPE, o modelo seria razoável, mas, assim como no caso anterior, dada a rejeição da normalidade, o modelo não é adequado.

Análise da série “Mean Temp (°C)”


```
analise_serie_temporal(df$`Mean Temp (°C)`)
```



Função de Autocorrelação



Função de Autocorrelação Parcial



Augmented Dickey-Fuller Test
alternative: stationary

Type 1: no drift no trend

	lag	ADF	p.value
[1,]	0	-6,30	0,01
[2,]	1	-16,07	0,01
[3,]	2	-22,97	0,01
[4,]	3	-17,87	0,01
[5,]	4	-13,51	0,01
[6,]	5	-8,43	0,01

Type 2: with drift no trend


	lag	ADF	p.value
[1,]	0	-6,67	0,01
[2,]	1	-17,56	0,01
[3,]	2	-28,10	0,01
[4,]	3	-26,49	0,01
[5,]	4	-26,58	0,01
[6,]	5	-21,86	0,01

Type 3: with drift and trend

	lag	ADF	p.value
[1,]	0	-6,68	0,01
[2,]	1	-17,56	0,01
[3,]	2	-28,11	0,01
[4,]	3	-26,54	0,01
[5,]	4	-26,72	0,01
[6,]	5	-22,08	0,01

Note: in fact, p.value = 0.01 means p.value <= 0.01

Residuals from ARIMA(2,0,2) with non-zero mean




Ljung-Box test

```
data: Residuals from ARIMA(2,0,2) with non-zero mean
Q* = 34,906, df = 6, p-value = 4,494e-06
```

```
Model df: 4. Total lags used: 10
```

Forecasts from ARIMA(2,0,2) with non-zero mean



```
$Modelo
Series: treinamento
ARIMA(2,0,2) with non-zero mean

Coefficients:
          ar1      ar2      ma1      ma2      mean
          1,7321 -0,9999 -1,6678  0,9478  3,6238
s.e.    0,0004   0,0001   0,0172  0,0161  0,1155

sigma^2 = 5,102:  log likelihood = -927,61
AIC=1867,21  AICc=1867,42  BIC=1891,37

$MAPE
[1] 20

$MAE
[1] 1,749858


$Classificacao
[1] "Razoável"
```

O teste ADF sugere estacionariedade da série. O modelo selecionado com o critério de BIC mínimo é ARIMA(2,0,2). O teste de Ljung-Box rejeita a hipótese nula de normalidade dos


resíduos. Pela avaliação do MAPE, o modelo seria razoável, mas, assim como nos casos anteriores, dada a rejeição da normalidade, o modelo não é adequado.

Análise da série “Extr Max Temp (°C)”


```
analise_serie_temporal(df$`Extr Max Temp (°C)`)
```



Função de Autocorrelação



Função de Autocorrelação Parcial



Augmented Dickey-Fuller Test
alternative: stationary

Type 1: no drift no trend

	lag	ADF	p.value
[1,]	0	-3,69	0,01
[2,]	1	-5,43	0,01
[3,]	2	-6,38	0,01
[4,]	3	-5,27	0,01
[5,]	4	-4,01	0,01
[6,]	5	-2,66	0,01

Type 2: with drift no trend


	lag	ADF	p.value
[1,]	0	-7,75	0,01
[2,]	1	-12,78	0,01
[3,]	2	-19,08	0,01
[4,]	3	-21,46	0,01
[5,]	4	-23,08	0,01
[6,]	5	-21,12	0,01

Type 3: with drift and trend

	lag	ADF	p.value
[1,]	0	-7,74	0,01
[2,]	1	-12,77	0,01
[3,]	2	-19,06	0,01
[4,]	3	-21,44	0,01
[5,]	4	-23,06	0,01
[6,]	5	-21,11	0,01

Note: in fact, p.value = 0.01 means p.value <= 0.01

Residuals from ARIMA(2,0,2) with non-zero mean




Ljung-Box test

```
data: Residuals from ARIMA(2,0,2) with non-zero mean
Q* = 40,475, df = 6, p-value = 3,674e-07
```

```
Model df: 4. Total lags used: 10
```

Forecasts from ARIMA(2,0,2) with non-zero mean



```
$Modelo
Series: treinamento
ARIMA(2,0,2) with non-zero mean

Coefficients:
          ar1      ar2      ma1      ma2      mean
          1,7266 -0,9954 -1,5165  0,7531  19,1258
s.e.      0,0039  0,0036  0,0376  0,0387  0,1705

sigma^2 = 15,52:  log likelihood = -1146,95
AIC=2305,9  AICc=2306,11  BIC=2330,01

$MAPE
[1] 191

$MAE
[1] 4,677359

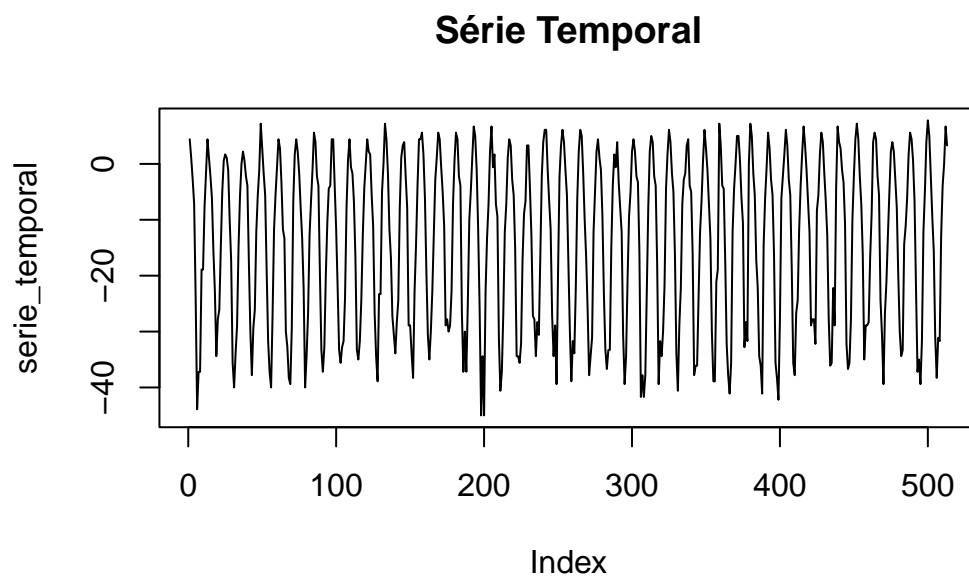
$Classificacao
[1] "Ruim"
```

O teste ADF sugere estacionariedade da série. O modelo selecionado com o critério de BIC mínimo é ARIMA(2,0,2). O teste de Ljung-Box rejeita a hipótese nula de normalidade dos


resíduos. O MAPE neste caso deu um valor estranhamente alto, o que por si só sugere que o modelo é ruim.

Análise da série “Extr Min Temp (°C)”


```
analise_serie_temporal(df$`Extr Min Temp (°C)`)
```



Função de Autocorrelação



Função de Autocorrelação Parcial



Augmented Dickey-Fuller Test
alternative: stationary

Type 1: no drift no trend

	lag	ADF	p.value
[1,]	0	-5,28	0,01
[2,]	1	-9,26	0,01
[3,]	2	-11,34	0,01
[4,]	3	-9,58	0,01
[5,]	4	-6,63	0,01
[6,]	5	-4,70	0,01


Type 2: with drift no trend

	lag	ADF	p.value
[1,]	0	-7,34	0,01
[2,]	1	-14,02	0,01
[3,]	2	-20,95	0,01
[4,]	3	-23,68	0,01
[5,]	4	-21,64	0,01
[6,]	5	-19,59	0,01

Type 3: with drift and trend

	lag	ADF	p.value
[1,]	0	-7,34	0,01
[2,]	1	-14,02	0,01
[3,]	2	-20,95	0,01
[4,]	3	-23,70	0,01
[5,]	4	-21,68	0,01
[6,]	5	-19,65	0,01

Note: in fact, p.value = 0.01 means p.value <= 0.01




Ljung-Box test

```
data: Residuals from ARIMA(2,0,2) with non-zero mean
Q* = 62,141, df = 6, p-value = 1,651e-11
```

```
Model df: 4. Total lags used: 10
```

Forecasts from ARIMA(2,0,2) with non-zero mean



```
$Modelo
Series: treinamento
ARIMA(2,0,2) with non-zero mean

Coefficients:
          ar1      ar2      ma1      ma2      mean
          1,7155 -0,9864 -1,2952  0,5168 -14,1626
s.e.      0,0083   0,0082   0,0675  0,0728   0,2060

sigma^2 = 26,06:  log likelihood = -1250,08
AIC=2512,16   AICc=2512,37   BIC=2536,26

$MAPE
[1] Inf

$MAE
[1] 5,316438

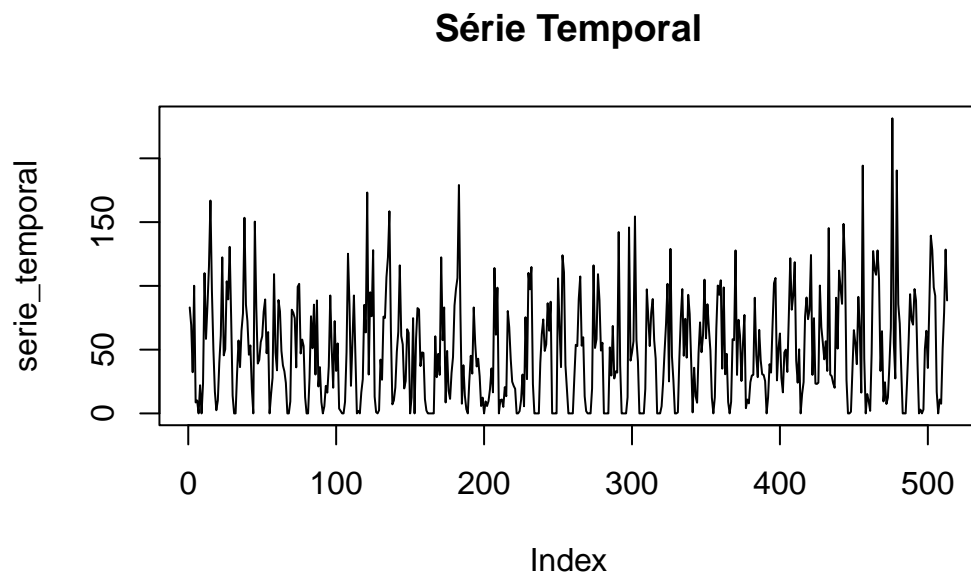
$Classificacao
[1] "Ruim"
```

O teste ADF sugere estacionariedade da série. O modelo selecionado com o critério de BIC


mínimo é ARIMA(2,0,2). O teste de Ljung-Box rejeita a hipótese nula de normalidade dos resíduos. O MAPE por si só sugere que o modelo é ruim.

Análise da série “Total Rain (mm)”


```
analise_serie_temporal(df$`Total Rain (mm)`)
```



Função de Autocorrelação



Função de Autocorrelação Parcial



Augmented Dickey-Fuller Test
alternative: stationary

Type 1: no drift no trend

	lag	ADF	p.value
[1,]	0	-8,41	0,01
[2,]	1	-6,25	0,01
[3,]	2	-5,64	0,01
[4,]	3	-5,47	0,01
[5,]	4	-5,44	0,01
[6,]	5	-4,48	0,01

Type 2: with drift no trend


	lag	ADF	p.value
[1,]	0	-14,4	0,01
[2,]	1	-11,7	0,01
[3,]	2	-11,6	0,01
[4,]	3	-12,4	0,01
[5,]	4	-14,3	0,01
[6,]	5	-13,6	0,01

Type 3: with drift and trend

	lag	ADF	p.value
[1,]	0	-14,5	0,01
[2,]	1	-11,7	0,01
[3,]	2	-11,6	0,01
[4,]	3	-12,4	0,01
[5,]	4	-14,4	0,01
[6,]	5	-13,7	0,01

Note: in fact, p.value = 0.01 means p.value <= 0.01

Residuals from ARIMA(1,0,0) with non-zero mean




Ljung-Box test

```
data: Residuals from ARIMA(1,0,0) with non-zero mean
Q* = 61,533, df = 9, p-value = 6,784e-10
```

```
Model df: 1. Total lags used: 10
```

Forecasts from ARIMA(1,0,0) with non-zero mean



```
$Modelo
Series: treinamento
ARIMA(1,0,0) with non-zero mean

Coefficients:
      ar1      mean
    0,4341  46,3389
s.e.  0,0447   3,0661

sigma^2 = 1245:  log likelihood = -2041,83
AIC=4089,66  AICc=4089,72  BIC=4101,71

$MAPE
[1] Inf

$MAE
[1] 38,49019

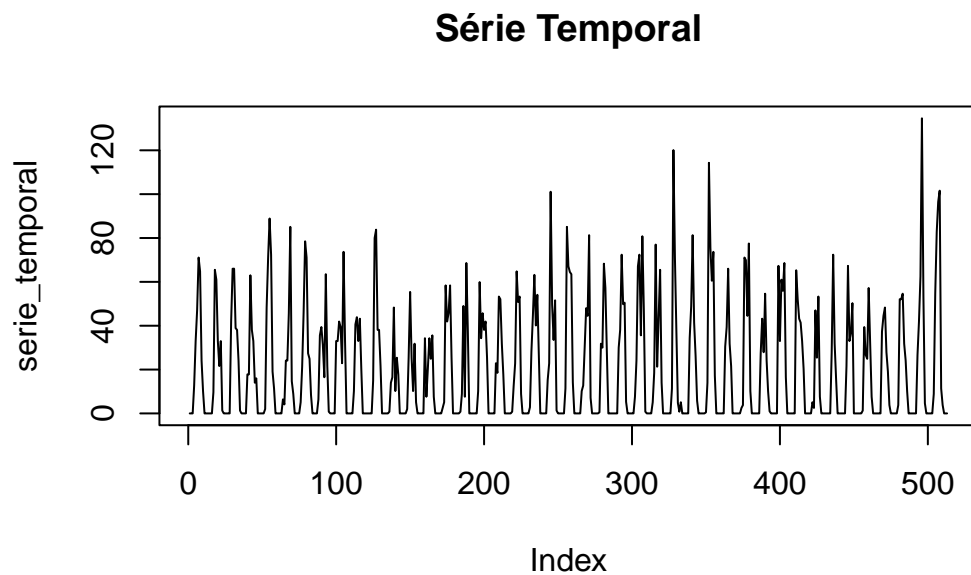
$Classificacao
[1] "Ruim"
```

O teste ADF sugere estacionariedade da série. O modelo selecionado com o critério de BIC


mínimo é ARIMA(2,0,2). O teste de Ljung-Box rejeita a hipótese nula de normalidade dos resíduos. O MAPE por si só sugere que o modelo é ruim.

Análise da série “Total Snow (cm)”


```
analise_serie_temporal(df$`Total Snow (cm)`)
```



Função de Autocorrelação



Função de Autocorrelação Parcial



Augmented Dickey-Fuller Test
alternative: stationary

Type 1: no drift no trend

	lag	ADF	p.value
[1,]	0	-8,55	0,01
[2,]	1	-8,40	0,01
[3,]	2	-8,71	0,01
[4,]	3	-9,27	0,01
[5,]	4	-8,18	0,01
[6,]	5	-7,15	0,01


Type 2: with drift no trend

	lag	ADF	p.value
[1,]	0	-11,3	0,01
[2,]	1	-11,7	0,01
[3,]	2	-13,1	0,01
[4,]	3	-15,7	0,01
[5,]	4	-15,9	0,01
[6,]	5	-16,4	0,01

Type 3: with drift and trend

	lag	ADF	p.value
[1,]	0	-11,2	0,01
[2,]	1	-11,7	0,01
[3,]	2	-13,1	0,01
[4,]	3	-15,7	0,01
[5,]	4	-15,9	0,01
[6,]	5	-16,4	0,01

Note: in fact, p.value = 0.01 means p.value <= 0.01




Ljung-Box test

```
data: Residuals from ARIMA(2,0,2) with non-zero mean
Q* = 62,648, df = 6, p-value = 1,302e-11
```

```
Model df: 4. Total lags used: 10
```

Forecasts from ARIMA(2,0,2) with non-zero mean



```
$Modelo
Series: treinamento
ARIMA(2,0,2) with non-zero mean

Coefficients:
      ar1      ar2      ma1      ma2      mean
    1,7285 -0,9988 -1,6814  0,9357  20,1621
s.e.  0,0018  0,0012  0,0174  0,0170  0,7356

sigma^2 = 253,5:  log likelihood = -1716,76
AIC=3445,53  AICc=3445,73  BIC=3469,62

$MAPE
[1] Inf

$MAE
[1] 18,63843


$Classificacao
[1] "Ruim"
```

O teste ADF sugere estacionariedade da série. O modelo selecionado com o critério de BIC


mínimo é ARIMA(2,0,2). O teste de Ljung-Box rejeita a hipótese nula de normalidade dos resíduos. O MAPE por si só sugere que o modelo é ruim.

Análise da série “Total Precip (mm)”


```
analise_serie_temporal(df$`Total Precip (mm)`)
```



Função de Autocorrelação



Função de Autocorrelação Parcial



Augmented Dickey-Fuller Test
alternative: stationary

Type 1: no drift no trend

	lag	ADF	p.value
[1,]	0	-6,83	0,0100
[2,]	1	-4,21	0,0100
[3,]	2	-2,91	0,0100
[4,]	3	-2,40	0,0177
[5,]	4	-2,20	0,0278
[6,]	5	-1,86	0,0636

Type 2: with drift no trend


	lag	ADF	p.value
[1,]	0	-19,51	0,01
[2,]	1	-14,06	0,01
[3,]	2	-11,02	0,01
[4,]	3	-9,66	0,01
[5,]	4	-9,80	0,01
[6,]	5	-8,99	0,01

Type 3: with drift and trend

	lag	ADF	p.value
[1,]	0	-19,60	0,01
[2,]	1	-14,17	0,01
[3,]	2	-11,11	0,01
[4,]	3	-9,78	0,01
[5,]	4	-9,92	0,01
[6,]	5	-9,13	0,01

Note: in fact, p.value = 0.01 means p.value <= 0.01

Residuals from ARIMA(1,0,0) with non-zero mean




Ljung-Box test

```
data: Residuals from ARIMA(1,0,0) with non-zero mean
Q* = 18,45, df = 9, p-value = 0,0303
```

```
Model df: 1. Total lags used: 10
```

Forecasts from ARIMA(1,0,0) with non-zero mean



```
$Modelo
Series: treinamento
ARIMA(1,0,0) with non-zero mean

Coefficients:
          ar1      mean
          0,1475  66,0447
s.e.      0,0490   1,8187

sigma^2 = 991,2:  log likelihood = -1995,05
AIC=3996,1   AICc=3996,15   BIC=4008,14

$MAPE
[1] 44

$MAE
[1] 30,54254

$Classificacao
[1] "Razoável"
```

O teste ADF não sugere estacionariedade da série. O modelo selecionado com o critério de BIC mínimo é ARIMA(1,0,0). O teste de Ljung-Box rejeita a hipótese nula de normalidade

dos resíduos sob $\alpha = 5$. Pela avaliação do MAPE, o modelo seria razoável, mas, assim como nos casos anteriores, dada a rejeição da normalidade e da estacionariedade, o modelo não é adequado.